

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
Кафедра биомедицинской информатики

БЛАГОДАРНЫЙ Артём Андреевич

**РАЗРАБОТКА НЕЙРОННОЙ СЕТИ ДЛЯ ПРЕДСКАЗАНИЯ
СВОЙСТВ ЛЕКАРСТВЕННО-ПОДОБНЫХ МОЛЕКУЛ**

Дипломная работа

Научный руководитель:
доктор физико-математических наук, профессор
А.В. Тузиков

Допущена к защите

«___» _____ 2026 г.

Заведующий кафедрой биомедицинской информатики
кандидат физико-математических наук, доцент В.И. Белько

Минск, 2026

ОГЛАВЛЕНИЕ

Введение	7
Глава 1. Теоретические основы прогнозирования ADMET-свойств .	9
1.1 Понятие ADMET-свойств	9
1.2 Роль вычислительного прогнозирования в разработке лекарств	10
1.3 Молекулярные представления	10
1.3.1 Молекулярные отпечатки	10
1.3.2 SMILES-представление	11
1.3.3 Молекулярные графы	11
1.4 Нейросетевые архитектуры для молекулярного прогнозирования	11
Глава 2. Данные и подготовка молекулярных представлений	13
2.1 Используемые наборы данных	13
2.2 Разбиение данных	13
2.3 Подготовка SMILES-последовательностей	14
2.4 Формирование молекулярных графов	14
2.5 Атомные признаки	17
2.6 Признаки химических связей	19
Глава 3. Архитектуры нейронных сетей.	22
3.1 Общая постановка задачи	22
3.2 Модель MorganMLP	22
3.3 Модель SmilesCNN	23
3.4 Графовая модель GINE	23
3.5 Модель Mamba	27
3.6 Transformer-модель	30
3.7 Сравнение размеров моделей	34
Глава 4. Предобучение моделей	35
4.1 Общая идея предобучения	35
4.2 Предобучение GINE	35
4.3 Предобучение Mamba	36
4.4 Предобучение Transformer	37
4.5 Параметры оптимизации	39
Глава 5. Дообучение моделей и оценка качества	40
5.1 Процедура дообучения	40
5.2 Метрики качества для задач классификации	40
5.3 Метрики качества для задач регрессии	42
Глава 6. Анализ экспериментальных результатов	43
6.1 Общая характеристика результатов	43
6.2 Результаты по задачам всасывания	43

6.3	Результаты по задачам распределения	44
6.4	Результаты по задачам метаболизма	45
6.5	Результаты по задачам выведения	46
6.6	Результаты по токсичности	47
6.7	Распределение побед моделей	48
Глава 7.	Сравнение с публичными результатами	50
7.1	Цель сравнения	50
7.2	Сопоставление метрик	50
7.3	Интерпретация сравнения	50
Заключение.		53

РЕФЕРАТ

Дипломная работа, 47 страниц, 7 рисунков, 20 источников, 1 таблица

Ключевые слова: ADMET-СВОЙСТВА, ГРАФОВЫЕ НЕЙРОННЫЕ СЕТИ, ПРОГНОЗИРОВАНИЕ СВОЙСТВ МОЛЕКУЛ, SMILES, GINE, MAMBA, TRANSFORMER, MORGAN FINGERPRINTS.

Объект исследования: химические соединения, представленные в виде SMILES-строк, молекулярных графов и молекулярных отпечатков.

Предмет исследования: нейросетевые методы прогнозирования ADMET-свойств молекул.

Методы исследования: теоретический анализ методов представления молекул и нейросетевых архитектур, подготовка и предобработка химических данных, предобучение моделей на неразмеченных данных, дообучение моделей на задачах прогнозирования ADMET-свойств, экспериментальное сравнение качества моделей с использованием метрик ROC-AUC, MAE и коэффициента Спирмена.

Цель работы: исследование и сравнение нейросетевых архитектур для прогнозирования ADMET-свойств химических соединений с использованием различных представлений молекул.

Результат: реализованы пять нейросетевых архитектур: MorganMLP на основе Morgan fingerprints, SmilesCNN для SMILES-последовательностей, графовая модель GINE, последовательностная модель Mamba и Transformer-модель. Проведено предобучение GINE, Mamba и Transformer с использованием восстановления замаскированных атомных признаков, предсказания молекулярных отпечатков. Выполнено дообучение моделей на отдельных ADMET-задачах и проведено сравнение качества. Наиболее устойчивые результаты среди рассмотренных моделей показала GINE, занявшая первое место на 16 задачах. Графовое представление молекулы является наиболее универсальным среди исследованных подходов, однако для отдельных свойств конкурентоспособны последовательностные и fingerprint-based модели.

Область применения: предварительный отбор лекарственных кандидатов, вычислительная оценка ADMET-свойств, разработка моделей машинного обучения для задач хемоинформатики и поиска лекарственных средств.

РЭФЕРАТ

Дыпломная работа, 47 старонак, 7 рысункаў, 20 крыніц, 1 табліца

Ключавыя словы: ADMET-УЛАСЦІВАСЦІ, ГРАФАВЫЯ НЕЙРОННЫЯ СЕТКІ, ПРАГНАЗАВАННЕ ЎЛАСЦІВАСЦЕЙ МАЛЕКУЛ, SMILES, GINE, MAMBA, TRANSFORMER, MORGAN FINGERPRINTS.

Аб’ект даследавання: хімічныя злучэнні, прадстаўленыя ў выглядзе SMILES-радкоў, малекулярных графаў і малекулярных адбіткаў.

Прадмет даследавання: нейрасеткавыя метады прагназавання ADMET-уласцівасцей малекул.

Метады даследавання: тэарэтычны аналіз метадаў прадстаўлення малекул і нейрасеткавых архітэктур, падрыхтоўка і папярэдняе апрацоўка хімічных даных, папярэдняе навучанне мадэляў на неразмечаных даных, данаўчанне мадэляў на задачах прагназавання ADMET-уласцівасцей, эксперыментальнае параўнанне якасці мадэляў з выкарыстаннем метрык ROC-AUC, MAE і каэфіцыента Спірмена.

Мэта работы: даследаванне і параўнанне нейрасеткавых архітэктур для прагназавання ADMET-уласцівасцей хімічных злучэнняў з выкарыстаннем розных прадстаўленняў малекул.

Вынік: рэалізаваны пяць нейрасеткавых архітэктур: MorganMLP на аснове Morgan fingerprints, SmilesCNN для SMILES-паслядоўнасцей, графавая мадэль GINE, паслядоўнасная мадэль Mamba і Transformer-мадэль. Праведзена папярэдняе навучанне GINE, Mamba і Transformer з выкарыстаннем аднаўлення замаскіраваных атамных прыкмет і прадказання малекулярных адбіткаў. Выканана данаўчанне мадэляў на асобных ADMET-задачах і праведзена параўнанне якасці. Найбольш устойлівыя вынікі сярод разгледжаных мадэляў паказала GINE, якая заняла першае месца ў 16 задачах. Графавае прадстаўленне малекулы з’яўляецца найбольш універсальным сярод даследаваных падыходаў, аднак для асобных уласцівасцей канкурэнтаздольнымі з’яўляюцца таксама паслядоўнасныя і fingerprint-based мадэлі.

Вобласць прымянення: папярэдні адбор лекавых кандыдатаў, вылічальная ацэнка ADMET-уласцівасцей, распрацоўка мадэляў машыннага навучання для задач хемаінфарматыкі і пошуку лекавых сродкаў.

ABSTRACT

Thesis, 47 pages, 7 figures, 20 references, 1 table

Keywords: ADMET PROPERTIES, SMILES, TRANSFORMER, MAMBA, MOLECULAR PROPERTY PREDICTION, GRAPH NEURAL NETWORKS, GINE, MORGAN FINGERPRINTS.

Object of research: chemical compounds represented as SMILES strings, molecular graphs, and molecular fingerprints.

Subject of research: neural network methods for predicting molecular ADMET properties.

Research methods: theoretical analysis of molecular representation methods and neural network architectures, preparation and preprocessing of chemical data, pretraining of models on unlabeled data, fine-tuning of models for ADMET property prediction tasks, and experimental comparison of model performance using ROC-AUC, MAE, and Spearman's rank correlation coefficient.

Aim of the work: to study and compare neural network architectures for predicting ADMET properties of chemical compounds using different molecular representations.

Results: five neural network architectures were implemented: MorganMLP based on Morgan fingerprints, SmilesCNN for SMILES sequences, the graph-based GINE model, the sequential Mamba model, and a Transformer-based model. GINE, Mamba, and Transformer were pretrained using masked atom feature reconstruction and molecular fingerprint prediction. The models were fine-tuned on individual ADMET tasks, and their performance was compared. Model GINE demonstrated the most stable results among the considered models, ranking first on 16 tasks. The graph representation of molecules proved to be the most universal among the studied approaches; however, for certain properties, sequential and fingerprint-based models were also competitive.

Field of application: preliminary screening of drug candidates, computational assessment of ADMET properties, and development of machine learning models for cheminformatics and drug discovery tasks.

ВВЕДЕНИЕ

На ранних этапах разработки лекарств биологическая активность сама по себе не является достаточным критерием отбора. Молекула может хорошо связываться с выбранной мишенью, но при этом обладать низкой растворимостью, плохо проходить через биологические барьеры, быстро выводиться из организма или проявлять токсичность. Поэтому вместе с активностью обычно рассматривают ADMET-характеристики соединения: всасывание, распределение, метаболизм, выведение и токсичность. Эти свойства напрямую влияют на то, сможет ли соединение перейти от первичного скрининга к дальнейшим доклиническим исследованиям [1].

Экспериментальное измерение ADMET-показателей требует отдельных лабораторных процедур и не может быть выполнено для каждой молекулы из большой виртуальной библиотеки. На практике сначала требуется сузить набор кандидатов, а уже затем проводить более дорогие экспериментальные проверки. В этой постановке вычислительные модели используются как предварительный фильтр: они не заменяют лабораторные измерения, но позволяют расставить соединения по приоритету и исключить заведомо менее перспективные варианты.

Один из распространённых подходов к прогнозированию свойств молекул основан на предварительном вычислении дескрипторов или молекулярных отпечатков. В этом случае химическая структура переводится в вектор фиксированной длины, после чего к нему применяются методы машинного обучения. Такой подход удобен вычислительно и хорошо подходит как базовая линия сравнения. Его ограничение состоит в том, что качество прогноза зависит от выбранного способа кодирования: если используемый набор признаков не отражает важные элементы структуры, последующая модель уже не сможет восстановить эту информацию.

Целью данной работы является исследование и экспериментальное сравнение нейросетевых архитектур для прогнозирования ADMET-свойств химических соединений при использовании разных молекулярных представлений: отпечатков Morgan, SMILES-последовательностей и молекулярных графов.

Для достижения поставленной цели были решены следующие задачи.

1. Рассмотреть основные способы представления молекул, используемые в задачах машинного обучения.
2. Подготовить наборы данных ADMET Benchmark и привести молекулы к выбранным форматам представления.
3. Реализовать нейронные модели.
4. Провести предобучение моделей GINE, Mamba и Transformer на вспо-

могательных задачах.

5. Дообучить модели на отдельных ADMET-задачах.

6. Оценить качество моделей на тестовых выборках с использованием ROC-AUC, MAE и коэффициента Спирмена.

7. Провести сравнительный анализ полученных результатов.

Объектом исследования являются химические соединения, представленные в виде SMILES-строк, молекулярных графов и молекулярных отпечатков.

Предметом исследования являются нейросетевые методы прогнозирования ADMET-свойств молекул.

В работе рассматриваются несколько архитектур: многослойный перцептрон на основе Morgan fingerprints, сверточная нейронная сеть для SMILES-последовательностей, графовая нейронная сеть GINE, последовательностная модель Mamba и Transformer-модель. Каждая модель использует свой способ работы с молекулярной структурой, что позволяет сравнить разные подходы к прогнозированию свойств соединений.

Научная новизна работы заключается в сравнении нескольких типов нейросетевых архитектур в рамках единого экспериментального протокола на наборе ADMET-задач. Также в работе рассматриваются разные способы предобучения моделей: восстановление замаскированных атомных признаков, предсказание молекулярных отпечатков, контрастивное обучение и masked language modeling для SMILES.

Практическая значимость работы состоит в том, что полученные результаты могут быть использованы при создании систем предварительного отбора лекарственных кандидатов. Кроме того, результаты работы могут помочь выбрать подходящую архитектуру модели для прогнозирования конкретных ADMET-свойств.

ГЛАВА 1

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ПРОГНОЗИРОВАНИЯ ADMET-СВОЙСТВ

1.1 Понятие ADMET-свойств

ADMET объединяет группу характеристик, описывающих поведение соединения после попадания в биологическую систему: absorption, distribution, metabolism, excretion и toxicity. Для лекарственного кандидата эти свойства важны не меньше, чем активность относительно целевой мишени. Они определяют, попадёт ли молекула в системный кровоток, достигнет ли нужной ткани, насколько быстро будет метаболизироваться и выводиться, а также не приведёт ли её применение к нежелательным токсическим эффектам.

Всасывание описывает способность соединения проникать через биологические барьеры и попадать в системный кровоток. К этой группе относятся такие свойства, как проницаемость через клеточные монослои Caco-2, кишечная абсорбция человека HIA, взаимодействие с P-glycoprotein и биодоступность. Плохое всасывание может привести к недостаточной концентрации препарата в крови и, как следствие, к отсутствию терапевтического эффекта [2].

Распределение определяет, как молекула распространяется между тканями и органами организма. Важными характеристиками являются проникновение через гематоэнцефалический барьер, связывание с белками плазмы крови и объём распределения. Эти параметры влияют на концентрацию препарата в целевых и нецелевых тканях.

Метаболизм связан с биохимическими превращениями молекулы, в основном в печени. Особое значение имеют ферменты семейства cytochrome P450, поскольку они участвуют в метаболизме большого числа лекарственных средств. Ингибирование или субстратность по отношению к ферментам CYP может приводить к лекарственным взаимодействиям и изменению концентрации препаратов в организме.

Выведение показывает, как быстро вещество и продукты его превращения удаляются из организма. К этому относятся такие показатели, как период полувыведения и клиренс. Они помогают определить, как часто и в какой дозе нужно принимать препарат, а также оценить, может ли вещество накапливаться в организме.

Токсичность отражает потенциально вредное воздействие молекулы на организм. В задачах ADMET-прогнозирования часто рассматриваются кардиотоксичность, острая токсичность и мутагенность. Ошибки на этапе оцен-

ки токсичности могут привести к прекращению разработки соединения на поздних стадиях, что может привести к значительным финансовым потерям.

1.2 Роль вычислительного прогнозирования в разработке лекарств

Разработка лекарственного средства является длительным и дорогостоящим процессом. На ранних этапах может быть синтезировано или виртуально сгенерировано большое количество соединений, однако лишь малая часть из них проходит дальнейшие стадии исследований. Поэтому особенно важны методы, позволяющие быстро отсеивать заведомо неперспективные молекулы.

Вычислительное прогнозирование ADMET-свойств позволяет выполнять предварительную оценку большого числа соединений до проведения дорогостоящих экспериментов. Такие методы применяются в виртуальном скрининге, оптимизации лидов, оценке безопасности и приоритизации кандидатов для синтеза.

Модели машинного обучения обучаются на известных экспериментальных данных и затем используются для прогнозирования свойств новых соединений. При этом качество модели зависит от представления молекулы, объёма и качества обучающих данных, архитектуры модели и выбранной схемы валидации.

1.3 Молекулярные представления

Для применения методов машинного обучения химическая структура должна быть преобразована в числовую форму. В данной работе используются три основных типа представлений: молекулярные отпечатки, SMILES-строки и молекулярные графы.

1.3.1 Молекулярные отпечатки

Молекулярные отпечатки представляют собой фиксированные по длине векторы, кодирующие наличие или отсутствие определённых химических фрагментов. Одним из наиболее распространённых типов являются Morgan fingerprints. Они строятся путём итеративного анализа локального окружения каждого атома [3].

В данной работе использовались Morgan fingerprints радиуса 2 и размерности 2048 бит. Радиус 2 означает, что при формировании признаков учитываются атомные окружения на расстоянии до двух связей от центрального атома. Полученный бинарный вектор служит входом для многослойного персептрона.

Преимуществом молекулярных отпечатков является простота, компактность и высокая вычислительная эффективность. Однако они имеют и огра-

ничения: процедура хеширования может приводить к коллизиям, а фиксированный набор признаков не всегда отражает сложные структурные зависимости.

1.3.2 SMILES-представление

SMILES — это строковая запись химической структуры, в которой атомы, связи, ветвления, циклы, заряды и стереохимия кодируются последовательностью символов. Например, одна и та же молекула может иметь несколько различных SMILES-записей в зависимости от порядка обхода графа [4].

SMILES-представление удобно для использования последовательностных моделей, таких как сверточные нейронные сети, рекуррентные сети, трансформеры и модели пространства состояний. В таком подходе молекула рассматривается как текстовая последовательность, а токены SMILES аналогичны словам или символам в задачах обработки естественного языка.

Важной особенностью SMILES является то, что строка является линейной сериализацией графа. Поэтому локальная близость символов в строке не всегда соответствует близости атомов в молекулярном графе. Тем не менее современные последовательностные модели способны извлекать полезные закономерности из SMILES-последовательностей.

1.3.3 Молекулярные графы

Молекулярный граф является наиболее естественным представлением химической структуры. В таком графе вершины соответствуют атомам, а рёбра — химическим связям. Каждая вершина и каждое ребро могут иметь набор признаков, описывающих химические свойства [5].

В данной работе атом описывается 33-мерным вектором признаков: тип атома, степень, формальный заряд, гибридизацию, ароматичность, принадлежность к циклу, число атомов водорода, атомную массу и валентность. Связь описывается 14-мерным вектором, включающим тип связи, сопряжённость, принадлежность к циклу и стереохимию.

Графовое представление позволяет явно учитывать топологию молекулы и использовать графовые нейронные сети для распространения информации между соседними атомами.

1.4 Нейросетевые архитектуры для молекулярного прогнозирования

Современные нейросетевые модели отличаются способом обработки молекулярного представления. Если молекула представлена вектором отпечатка, естественным выбором является многослойный персептрон. Если молекула представлена строкой SMILES, применяются последовательностные модели. Если используется граф, применяются графовые нейронные сети.

Общая задача прогнозирования молекулярного свойства может быть записана следующим образом. Пусть молекула m имеет представление x_m , а целевое свойство обозначается y_m . Необходимо построить модель f_θ , параметризованную θ , такую что:

$$\hat{y}_m = f_\theta(x_m), \quad (1.1)$$

где $\hat{y}_m$ — прогноз модели.

Для задач регрессии модель обучается минимизировать ошибку между истинным и предсказанным значением свойства. Для задач бинарной классификации модель прогнозирует логит, который затем преобразуется в вероятность с помощью сигмоидальной функции:

$$p_m = \sigma(\hat{y}_m) = \frac{1}{1 + e^{-\hat{y}_m}}. \quad (1.2)$$

ГЛАВА 2

ДАННЫЕ И ПОДГОТОВКА МОЛЕКУЛЯРНЫХ ПРЕДСТАВЛЕНИЙ

2.1 Используемые наборы данных

В работе использовались наборы данных из группы ADMET Benchmark, предоставляемой Therapeutics Data Commons. Данная группа включает стандартизованные задачи прогнозирования свойств, относящихся к всасыванию, распределению, метаболизму, выведению и токсичности.

Использование стандартизованного набора задач имеет несколько преимуществ. Во-первых, оно обеспечивает воспроизводимость результатов. Во-вторых, позволяет сравнивать полученные результаты с другими исследованиями. В-третьих, снижает риск ошибок, связанных с произвольным разбиением данных на обучающую, валидационную и тестовую выборки.

В работе были рассмотрены следующие группы задач:

1. всасывание и физико-химические свойства: Caco2, HIA, Bioavailability, Pgp, Lipophilicity, Solubility;
2. распределение: BBB, PPBR, VDss;
3. метаболизм: ингибирование CYP2C19, CYP2D6, CYP3A4, CYP1A2, CYP2C9, а также субстратность CYP2C9, CYP2D6, CYP3A4;
4. выведение: Half-Life, Clearance Hepatocyte, Clearance Microsome;
5. токсичность: LD50 и hERG.

Большинство задач классификации оценивались с помощью ROC-AUC, а задачи регрессии — с помощью MAE и коэффициента Спирмена.

2.2 Разбиение данных

Для большинства задач использовалось scaffold-разбиение, принятое в TDC. При таком разбиении молекулы с близкими химическими каркасами по возможности попадают в одну и ту же часть выборки. Поэтому тестовая выборка содержит структуры, менее похожие на обучающие, чем при случайном split. Такая постановка ближе к практическому применению модели, где требуется делать прогноз для новых химических серий.

Общее разбиение выполнялось в пропорции:

$$D = D_{\text{train}} \cup D_{\text{valid}} \cup D_{\text{test}}, \quad (2.1)$$

где обучающая, валидационная и тестовая выборки составляли соответственно 80%, 10% и 10% от исходного набора данных.

2.3 Подготовка SMILES-последовательностей

SMILES-строки были собраны из всех обучающих, валидационных и тестовых файлов, а также дополнены молекулами из набора ZINC, использованного для предобучения. Максимальная длина последовательности была ограничена значением 256 токенов:

$$L_{\max} = 256. \quad (2.2)$$

Такое ограничение позволяет обрабатывать подавляющее большинство молекул (99,98%), сохраняя приемлемые вычислительные затраты.

Для обработки SMILES был обучен специализированный токенизатор. Он преобразует строку в последовательность целочисленных идентификаторов:

$$s = (c_1, c_2, \dots, c_L) \rightarrow x = (t_1, t_2, \dots, t_L), \quad (2.3)$$

где c_i — символ или токен SMILES, t_i — соответствующий индекс в словаре.

Для последовательностных моделей дополнительно использовалась аугментация SMILES. Для одной молекулы генерировались альтернативные корректные записи, соответствующие разным порядкам обхода молекулярного графа. Это важно для моделей, работающих со строкой: без такой процедуры они могут переобучаться на особенности канонической записи, хотя химическая структура при этом остаётся той же самой.

2.4 Формирование молекулярных графов

Молекулярные графы формировались на основе строкового представления молекул в формате SMILES (*Simplified Molecular Input Line Entry System*) с использованием библиотеки RDKit [2]. Формат SMILES позволяет представить химическую структуру молекулы в виде строки, которая затем может быть преобразована в объект молекулы и далее в графовое представление.

В данной работе каждая молекула рассматривалась как граф $G = (V, E)$, где V — множество вершин, соответствующих атомам молекулы, а E — множество рёбер, соответствующих химическим связям между атомами. Таким образом, атомы молекулы задают вершины графа, а ковалентные связи между ними определяют его рёбра.

Для каждой SMILES-строки выполнялась последовательность операций:

1. разбор SMILES-строки средствами RDKit;
2. проверка корректности полученного молекулярного объекта;
3. извлечение признаков атомов;
4. извлечение информации о химических связях;
5. построение графового представления молекулы;
6. вычисление дескриптора в виде Morgan fingerprint.

В результате для каждой молекулы формировался объект графа, содержащий следующие компоненты:

1. матрицу признаков вершин $X \in \mathbb{R}^{N \times 33}$, где N — число атомов в молекуле, а каждая строка матрицы соответствует вектору признаков отдельного атома;

2. матрицу индексов рёбер $E \in \mathbb{N}^{2 \times M}$, задающую пары вершин, между которыми существуют химические связи;

3. матрицу признаков рёбер $A \in \mathbb{R}^{M \times 14}$, где M — число направленных рёбер в графе, а каждая строка описывает признаки соответствующей химической связи;

4. Morgan fingerprint размерности 2048, обозначаемый как $f_{\text{Morgan}} \in \mathbb{R}^{2048}$.

Матрица признаков вершин X содержит численное описание атомов молекулы. Для каждого атома формировался вектор признаков $x_i \in \mathbb{R}^{33}$, где $i = 1, \dots, N$. Данный вектор включает химически значимые характеристики атома, которые могут быть извлечены средствами RDKit. К таким характеристикам относятся тип атома, степень атома, формальный заряд, тип гибридизации, ароматичность, количество связанных атомов водорода, принадлежность атому к циклической структуре и другие параметры. Использование подобных признаков позволяет модели учитывать не только структуру молекулярного графа, но и химическую природу отдельных атомов.

Матрица индексов рёбер E описывает связность молекулярного графа. Поскольку химические связи в молекулах являются неориентированными, каждая связь между атомами i и j добавлялась в граф в двух направлениях: (i, j) и (j, i) . Иными словами, для каждой химической связи формировались два направленных ребра: $i \rightarrow j$ и $j \rightarrow i$.

Такое представление необходимо, поскольку многие реализации графовых нейронных сетей выполняют передачу сообщений вдоль направленных рёбер. Дублирование рёбер в обоих направлениях обеспечивает двунаправленную передачу информации между связанными атомами и позволяет модели учитывать влияние каждого атома на его соседей.

Матрица признаков рёбер A содержит описание химических связей. Для каждого направленного ребра формировался вектор признаков $a_k \in \mathbb{R}^{14}$, где $k = 1, \dots, M$. Эти признаки характеризуют свойства соответствующей химической связи. В частности, они могут включать тип связи, например одинарную, двойную, тройную или ароматическую связь, признак сопряжённости, принадлежность связи к кольцу, а также стереохимические характеристики. Поскольку каждая неориентированная химическая связь представляется двумя направленными рёбрами, её признаки дублируются для обоих направлений.

Дополнительно для каждой молекулы рассчитывался Morgan fingerprint длиной 2048 бит. Данный дескриптор использовался как компактное глобальное описание структуры молекулы. В отличие от графового представления, размерность fingerprint не зависит от числа атомов: как для малых, так и для

крупных молекул получается вектор одной и той же длины. При этом Morgan fingerprint учитывает локальные атомные окружения на заданных радиусах, что позволяет зафиксировать наличие характерных химических фрагментов.

В результате для каждой корректно обработанной SMILES-строки формировалось представление

$$\mathcal{D}_{\text{mol}} = (X, E, A, f_{\text{Morgan}}),$$

где X задаёт признаки атомов, E описывает структуру связей, A содержит признаки рёбер, а f_{Morgan} соответствует Morgan fingerprint. Такое представление объединяет два типа информации: графовая часть отражает топологию молекулы и локальные свойства атомов и связей, а fingerprint добавляет фиксированное векторное описание структурных фрагментов.

Отдельно обрабатывались SMILES-строки, которые не удалось корректно преобразовать в объект молекулы средствами RDKit. Такие случаи могут возникать из-за ошибок в записи SMILES, некорректных валентностей, нестандартных структур или ограничений самой библиотеки. Чтобы не удалять соответствующие объекты из датасета и сохранить исходный порядок данных, для них создавался фиктивный граф.

Фиктивный граф состоял из одной вершины с нулевым вектором признаков:

$$X_{\text{dummy}} = \mathbf{0}^{1 \times 33}.$$

Рёбра в таком графе отсутствовали:

$$E_{\text{dummy}} = \emptyset,$$

а матрица признаков рёбер также была пустой:

$$A_{\text{dummy}} = \emptyset.$$

Morgan fingerprint для такой записи задавался нулевым вектором размерности 2048:

$$f_{\text{Morgan}}^{\text{dummy}} = \mathbf{0}^{2048}.$$

Кроме того, для каждого объекта сохранялся флаг корректности. Для успешно распознанных молекул устанавливалось значение

$$\text{valid} = 1,$$

а для фиктивных графов —

$$\text{valid} = 0.$$

Этот флаг позволял на последующих этапах отличать реальные молекулярные графы от объектов, созданных только для сохранения структуры датасета.

Такой способ обработки делает пайплайн более устойчивым: невалидные SMILES-строки не прерывают предобработку и не приводят к смещению индексов между исходными объектами и сформированными входными данными. Это особенно важно для крупных химических наборов данных, где ошибки в записях или нестандартные молекулы встречаются достаточно часто.

Таким образом, каждая запись датасета приводилась к единому формату, пригодному для подачи в графовую нейронную сеть. Для валидных молекул использовалось полное представление, а для невалидных записей использовалось фиктивное представление.

2.5 Атомные признаки

Для описания атомов в молекулярном графе использовались векторы признаков фиксированной размерности. Каждому атому $v_i \in V$ сопоставлялся вектор $x_i \in \mathbb{R}^{33}$, где 33 соответствует итоговому числу признаков. Для всей молекулы атомные векторы объединялись в матрицу признаков вершин $X \in \mathbb{R}^{N \times 33}$, где N — количество атомов в молекуле.

Признаки атомов формировались с помощью библиотеки RDKit на основе химических характеристик, которые обычно используются при описании молекулярной структуры. В итоговый набор были включены как категориальные признаки, так и бинарные и численные характеристики. Для каждого атома учитывались следующие параметры:

1. тип атома;
2. степень атома;
3. формальный заряд;
4. тип гибридизации;
5. принадлежность к ароматической системе;
6. принадлежность к циклу;
7. число присоединённых атомов водорода;
8. атомная масса;
9. валентность.

Категориальные признаки кодировались в формате one-hot. Для каждого такого признака заранее задавался набор возможных значений. Если в молекуле встречалось значение, отсутствующее в этом наборе, оно относилось к отдельной категории *unknown*. Это было сделано для того, чтобы модель могла корректно обрабатывать редкие элементы или нестандартные состояния атомов, которые не обязательно встречаются в обучающей выборке [6].

В общем виде one-hot кодирование можно записать следующим образом:

$$e(c) \in \{0, 1\}^{K+1},$$

где K — число заранее заданных категорий, а последняя компонента вектора отвечает за неизвестное значение. Если значение признака входит в список известных категорий, единица ставится в соответствующую позицию,

остальные компоненты принимают значение 0. Если значение не найдено, единица помещается в последнюю компоненту.

Одним из основных признаков является тип атома, то есть химический элемент, которому соответствует вершина графа. Этот признак важен, поскольку разные элементы обладают разными физико-химическими свойствами. Например, атомы углерода, кислорода, азота, серы и галогенов отличаются валентностью, электроотрицательностью и характером участия в химических связях. Поэтому информация о типе атома является базовой для дальнейшего анализа молекулы.

Степень атома показывает, сколько соседних атомов непосредственно связано с данным атомом. Если множество соседей атома v_i обозначить через $\mathcal{N}(i)$, то степень можно записать как

$$d_i = |\mathcal{N}(i)|.$$

Этот признак позволяет описать локальную связность атома: является ли он терминальным, находится ли внутри цепи или входит в более разветвлённый фрагмент молекулы.

Формальный заряд отражает зарядовое состояние атома. Наличие положительного или отрицательного заряда может заметно влиять на полярность молекулы, её растворимость, реакционную способность и возможность образования межмолекулярных взаимодействий. Поэтому формальный заряд также был включён в вектор признаков как категориальная характеристика.

Тип гибридизации описывает электронное состояние атома и связанную с ним локальную геометрию. В частности, для органических молекул часто встречаются варианты sp , sp^2 и sp^3 . Учёт гибридизации позволяет модели косвенно учитывать пространственную организацию молекулы, так как разные типы гибридизации соответствуют различным углам между связями и разной форме локального окружения атома.

Дополнительно использовался бинарный признак ароматичности:

$$h_{\text{arom}} \in \{0, 1\}.$$

Он показывает, принадлежит ли атом ароматической системе. Такой признак важен, поскольку ароматические фрагменты обладают особым распределением электронной плотности и часто встречаются в биологически активных соединениях.

Аналогично задавался признак принадлежности атома к циклу:

$$h_{\text{ring}} \in \{0, 1\},$$

он показывает, входит ли атом в состав какого-либо кольца. Кольцевые структуры существенно влияют на жёсткость молекулы, её конформационную подвижность и характер взаимодействия с другими молекулами, поэтому такой признак полезен при построении молекулярного представления.

Число присоединённых атомов водорода использовалось как численный признак. Оно характеризует насыщенность атома и даёт дополнительную информацию о его ближайшем химическом окружении. Чтобы привести этот признак к масштабу, сопоставимому с бинарными компонентами, использовалась нормировка:

$$x_{\text{H}} = \frac{n_{\text{H}}}{4},$$

где n_{H} — число атомов водорода, связанных с данным атомом. Деление на 4 выбрано потому, что для большинства органических молекул число водородов при одном атоме обычно не превышает этого значения.

Атомная масса также добавлялась в вектор признаков как непрерывная характеристика. Поскольку её значения могут быть существенно больше бинарных признаков, она нормировалась следующим образом:

$$x_{\text{mass}} = \frac{m}{200},$$

где m — атомная масса. Такая нормировка уменьшает различие масштабов между признаками и не позволяет массе непропорционально влиять на обучение модели.

Ещё одним численным признаком была валентность атома. Она отражает число связей, которые атом образует в данной молекуле, с учётом их кратности. Для приведения этого признака к небольшому диапазону использовалась нормировка:

$$x_{\text{val}} = \frac{\nu}{8},$$

где ν — валентность атома. Деление на 8 позволяет сделать значения валентности сопоставимыми с остальными компонентами признакового вектора.

Итоговый атомный вектор представлял собой конкатенацию всех перечисленных компонентов:

$$x_i = [x_{\text{type}}, x_{\text{degree}}, x_{\text{charge}}, x_{\text{hyb}}, h_{\text{arom}}, h_{\text{ring}}, x_{\text{H}}, x_{\text{mass}}, x_{\text{val}}]. \quad (2.4)$$

После объединения всех категориальных, бинарных и нормированных численных признаков размерность вектора составляла 33.

Таким образом, выбранное атомное представление объединяет несколько уровней информации об атоме: его химическую природу, локальную связность, зарядовое и электронное состояние, участие в циклах и ароматических системах, а также нормированные численные характеристики. Такое описание достаточно компактно, но при этом сохраняет основные химически значимые свойства, необходимые для обучения графовой нейронной сети.

2.6 Признаки химических связей

При построении молекулярного графа учитывались не только признаки атомов, но и признаки химических связей. В таком графе атомы представлены вершинами, а связи между ними — рёбрами. Поэтому для описания

молекулы важно знать не только то, какие атомы соединены между собой, но и каким именно типом химической связи они соединены.

Для каждой связи формировался вектор признаков фиксированной размерности. Ребру $e_k \in E$ сопоставлялся вектор

$$a_k \in \mathbb{R}^{14},$$

где 14 — итоговая размерность описания связи. Все векторы рёбер одной молекулы объединялись в матрицу

$$A \in \mathbb{R}^{M \times 14},$$

где M — число направленных рёбер в графе.

Химические связи по своей природе не имеют направления. Однако при работе с графовыми нейронными сетями удобно представлять каждую связь двумя направленными рёбрами. Поэтому связь между атомами i и j добавлялась в граф в двух направлениях:

$$i \rightarrow j \quad \text{и} \quad j \rightarrow i.$$

Оба направленных ребра имели одинаковый вектор признаков, так как соответствовали одной и той же химической связи. Такое представление позволяет модели передавать информацию в обе стороны между связанными атомами.

Вектор признаков связи включал следующие характеристики:

1. тип связи;
2. признак сопряжённости;
3. признак принадлежности связи к циклу;
4. стереохимическую конфигурацию.

Тип связи задавался категориально и кодировался с помощью one-hot представления. В данной работе учитывались основные типы связей:

1. одинарная связь;
2. двойная связь;
3. тройная связь;
4. ароматическая связь.

Такое кодирование позволяет явно указать, к какому типу относится конкретная связь. Это важно, поскольку разные типы связей по-разному влияют на геометрию и свойства молекулы. Например, одинарные связи обычно допускают вращение вокруг своей оси, тогда как двойные и тройные связи делают соответствующий фрагмент более жёстким. Ароматические связи, в свою очередь, связаны с делокализацией электронной плотности и имеют особое значение при описании органических молекул.

Признак сопряжённости показывал, входит ли связь в сопряжённую систему. Он задавался бинарной величиной:

$$conj_k \in \{0, 1\}.$$

Если $conj_k = 1$, связь считалась сопряжённой; если $conj_k = 0$, она не относилась к сопряжённой системе. Сопряжённые фрагменты важны, так как в них происходит делокализация электронов. Это может влиять на электронную структуру молекулы, её реакционную способность, оптические свойства и характер взаимодействия с другими молекулами.

Отдельно учитывалось, входит ли связь в состав кольца. Этот признак также задавался бинарно:

$$ring_k \in \{0, 1\}.$$

Значение $ring_k = 1$ означает, что связь принадлежит циклическому фрагменту молекулы, а $ring_k = 0$ — что она не входит в цикл. Кольцевые структуры часто заметно влияют на пространственную форму молекулы: они могут ограничивать вращение вокруг связей, повышать жёсткость структуры и задавать определённую конформацию. Поэтому информация о принадлежности связи к циклу является полезной для графовой модели.

Стереохимическая конфигурация описывает пространственное расположение заместителей относительно связи. Этот признак особенно важен в тех случаях, когда молекулы имеют одинаковую топологию, но отличаются пространственным строением. В общем виде вектор признаков связи представлялся как объединение нескольких блоков:

$$a_k = [a_{type}, a_{conj}, a_{ring}, a_{stereo}] , \quad (2.5)$$

где a_{type} — кодирование типа связи, a_{conj} — бинарный признак сопряжённости, a_{ring} — бинарный признак принадлежности к циклу, а a_{stereo} — категориальное кодирование стереохимической конфигурации. После объединения всех компонентов размерность вектора a_k составляла 14.

Использование признаков связей делает молекулярный граф более информативным. Если учитывать только наличие ребра между двумя атомами, то одинарные, двойные, тройные и ароматические связи будут представлены одинаково. В этом случае модель потеряет существенную часть химической информации. Добавление признаков рёбер позволяет различать связи по их химической природе и лучше описывать локальную структуру молекулы.

Таким образом, каждая химическая связь в молекулярном графе описывалась 14-мерным вектором, который включал тип связи, признаки сопряжённости и принадлежности к циклу, а также стереохимическую конфигурацию. Такое представление позволяет учитывать не только топологию молекулы, но и особенности химического взаимодействия между связанными атомами.

ГЛАВА 3

АРХИТЕКТУРЫ НЕЙРОННЫХ СЕТЕЙ

3.1 Общая постановка задачи

Все рассматриваемые модели решают задачу прогнозирования молекулярного свойства. Пусть имеется обучающая выборка:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n, \quad (3.1)$$

где x_i — представление молекулы, y_i — целевое значение свойства.

Для задач регрессии оптимизировалась функция потерь Smooth L1:

$$\mathcal{L}_{\text{reg}} = \begin{cases} 0.5(\hat{y} - y)^2, & |\hat{y} - y| < 1, \\ |\hat{y} - y| - 0.5, & \text{иначе.} \end{cases} \quad (3.2)$$

Для задач классификации использовалась бинарная кросс-энтропия с логитами:

$$\mathcal{L}_{\text{cls}} = -y \log \sigma(\hat{y}) - (1 - y) \log(1 - \sigma(\hat{y})). \quad (3.3)$$

3.2 Модель MorganMLP

MorganMLP является базовой моделью, использующей Morgan fingerprints в качестве входного представления. Каждая молекула кодируется бинарным вектором размерности 2048, который подаётся на многослойный персептрон.

Архитектура содержит три скрытых полносвязных слоя с размерностями 1024, 512 и 128 нейронов. После первых двух слоёв применяется dropout-регуляризация, а нелинейность задаётся функцией ReLU:

$$h_{k+1} = \text{ReLU}(W_k h_k + b_k). \quad (3.4)$$

Итоговый слой формирует одно выходное значение, используемое как прогноз свойства или логит класса.

Преимущество MorganMLP заключается в простоте и вычислительной эффективности. Недостатком является зависимость от заранее заданного способа кодирования молекулы [8].

3.3 Модель SmilesCNN

SmilesCNN обрабатывает молекулу как последовательность токенов. Сначала каждый токен преобразуется в вектор вложения размерности 128:

$$e_i = E[t_i], \quad (3.5)$$

где E — матрица эмбедингов.

Затем последовательность обрабатывается тремя одномерными сверточными слоями с числом фильтров 64, 96 и 128 соответственно. Все свёртки используют ядро размера 5. После каждой свёртки применяются BatchNorm, ReLU и dropout.

Сверточная операция может быть записана как:

$$h_i^{(k)} = \phi \left(\sum_{j=-r}^r W_j x_{i+j}^{(k-1)} + b \right), \quad (3.6)$$

где r определяется размером ядра, а ϕ — нелинейная функция активации.

После сверточного блока применяются глобальное максимальное и среднее агрегирование по длине последовательности. Полученные векторы объединяются и передаются в полносвязную голову прогнозирования.

3.4 Графовая модель GINE

Для работы с молекулярными графами в данной работе использовалась графовая нейронная сеть GINE (*Graph Isomorphism Network with Edge features*). По сути, GINE является расширением архитектуры GIN (*Graph Isomorphism Network*), но, в отличие от базовой версии, она позволяет учитывать не только признаки вершин, но и признаки рёбер [7]. Для молекулярных данных это особенно существенно, поскольку связь между атомами не является просто фактом соседства. Химические связи могут быть одинарными, двойными, тройными, ароматическими, сопряжёнными, входить в циклы, а также иметь различные стереохимические характеристики. Поэтому при построении модели важно передавать информацию не только о том, какие атомы соединены, но и о том, каким именно типом связи они соединены [14].

Молекула представляется в виде графа

$$G = (V, E),$$

где V обозначает множество вершин, соответствующих атомам, а E — множество рёбер, соответствующих химическим связям между ними. Каждой вершине $v \in V$ сопоставляется вектор атомных признаков

$$x_v \in \mathbb{R}^{33},$$

а каждому ребру $(u, v) \in E$ — вектор признаков связи

$$a_{uv} \in \mathbb{R}^{14}.$$

Таким образом, модель получает на вход не только структуру молекулы как графа, но и дополнительную химическую информацию об атомах и связях.

Основная идея GINE состоит в последовательной передаче сообщений между соседними вершинами графа. На каждом слое вершина обновляет своё представление, используя собственное текущее состояние, представления соседних вершин и признаки рёбер, соединяющих её с этими соседями. После нескольких таких шагов представление атома начинает содержать информацию не только о самом атоме, но и о его локальном химическом окружении на расстоянии нескольких связей.

Перед применением GINE-слоёв исходные признаки атомов переводились в скрытое пространство размерности 256. Для этого использовалось линейное преобразование:

$$h_v^{(0)} = W_x x_v + b_x, \quad (3.7)$$

где $x_v \in \mathbb{R}^{33}$ — исходный вектор признаков атома, W_x и b_x — обучаемые параметры линейного слоя, а $h_v^{(0)} \in \mathbb{R}^{256}$ — начальное скрытое представление вершины.

Аналогичным образом признаки рёбер также приводились к той же скрытой размерности. Это необходимо для того, чтобы их можно было использовать совместно с представлениями вершин при вычислении сообщений. Для ребра (u, v) выполнялось преобразование:

$$e_{uv} = W_e a_{uv} + b_e, \quad (3.8)$$

где $a_{uv} \in \mathbb{R}^{14}$ — исходный вектор признаков химической связи, W_e и b_e — обучаемые параметры, а $e_{uv} \in \mathbb{R}^{256}$ — скрытое представление ребра.

Далее выполнялось несколько слоёв передачи сообщений. На k -м слое каждая вершина v собирала информацию от своих соседей $\mathcal{N}(v)$. Обновление представления вершины в GINE можно записать следующим образом:

$$h_v^{(k)} = \text{MLP}^{(k)} \left((1 + \epsilon^{(k)}) h_v^{(k-1)} + \sum_{u \in \mathcal{N}(v)} \text{ReLU} \left(h_u^{(k-1)} + e_{uv} \right) \right), \quad (3.9)$$

где $h_v^{(k-1)}$ — представление вершины v на предыдущем слое, $h_u^{(k-1)}$ — представление соседней вершины u , e_{uv} — скрытое представление ребра между вершинами u и v , $\epsilon^{(k)}$ — обучаемый параметр, а $\text{MLP}^{(k)}$ — многослойный перцептрон, используемый на данном слое.

Первое слагаемое,

$$(1 + \epsilon^{(k)})h_v^{(k-1)},$$

отвечает за сохранение собственной информации вершины. Параметр $\epsilon^{(k)}$ позволяет модели самостоятельно настраивать, насколько сильно нужно учитывать прежнее состояние вершины по сравнению с информацией, поступающей от соседей. Это одна из важных особенностей архитектур GIN и GINE, поскольку такая схема помогает лучше различать локальные структуры графа.

Сумма по соседям

$$\sum_{u \in \mathcal{N}(v)}$$

описывает агрегацию сообщений от атомов, непосредственно связанных с атомом v . В отличие от классической GIN, в модели GINE сообщение зависит не только от соседней вершины, но и от признаков связи между вершинами. В отдельном виде сообщение от вершины u к вершине v можно записать так:

$$m_{u \rightarrow v}^{(k)} = \text{ReLU} \left(h_u^{(k-1)} + e_{uv} \right). \quad (3.10)$$

Благодаря этому модель учитывает тип химической связи при передаче информации между атомами. Например, соседний атом, связанный одинарной связью, может вносить иной вклад, чем атом, соединённый двойной или ароматической связью.

После применения $\text{MLP}^{(k)}$ использовались операции, которые повышают устойчивость обучения. В частности, после каждого GINE-слоя применялась нормализация GraphNorm:

$$\tilde{h}_v^{(k)} = \text{GraphNorm} \left(h_v^{(k)} \right). \quad (3.11)$$

GraphNorm выполняет нормализацию признаков внутри каждого отдельного графа. Это полезно для молекулярных данных, поскольку молекулы в одном батче могут заметно отличаться по размеру: одни содержат небольшое число атомов и связей, другие имеют более сложную структуру. Нормализация помогает сделать обучение более стабильным в таких условиях [15].

После нормализации применялась функция активации GELU:

$$\hat{h}_v^{(k)} = \text{GELU} \left(\tilde{h}_v^{(k)} \right). \quad (3.12)$$

GELU задаёт гладкую нелинейность и часто используется в современных нейросетевых архитектурах, поскольку позволяет модели строить более гибкие представления данных.

Для снижения риска переобучения дополнительно использовался dropout:

$$\bar{h}_v^{(k)} = \text{Dropout} \left(\hat{h}_v^{(k)} \right). \quad (3.13)$$

Во время обучения dropout случайным образом зануляет часть компонент скрытого представления. За счёт этого модель меньше полагается на отдельные признаки и, как правило, лучше обобщается на новых данных.

Также в архитектуру были добавлены остаточные соединения. После обработки очередного слоя новое представление вершины складывалось с её представлением с предыдущего слоя:

$$h_v^{(k)} \leftarrow h_v^{(k-1)} + \bar{h}_v^{(k)}. \quad (3.14)$$

Такие соединения упрощают обучение более глубоких графовых моделей, улучшают прохождение градиента и помогают сохранять информацию, полученную на ранних слоях. Это особенно важно для графовых нейронных сетей, поскольку при увеличении числа слоёв может возникать эффект чрезмерного сглаживания, когда представления разных вершин становятся слишком похожими друг на друга.

После нескольких слоёв передачи сообщений каждая вершина получает итоговое скрытое представление h_v , в котором содержится информация об атоме и его локальном окружении. Но для предсказания свойств всей молекулы требуется не набор отдельных вершинных представлений, а один общий вектор, описывающий молекулу целиком, поэтому использовалась операция пулинг.

В данной работе применялось объединение глобального среднего и максимального пулинга:

$$h_G = \left[\frac{1}{|V|} \sum_{v \in V} h_v ; \max_{v \in V} h_v \right], \quad (3.15)$$

где $|V|$ — число вершин в графе,

$$\frac{1}{|V|} \sum_{v \in V} h_v$$

соответствует среднему представлению по всем атомам молекулы, а

$$\max_{v \in V} h_v$$

обозначает покомпонентный максимум по всем вершинам графа.

Пулинг позволяет учесть общий вклад всех атомов и отражает усреднённое распределение признаков в молекуле. А максимальный пулинг, наоборот, выделяет наиболее выраженные локальные фрагменты или атомные окружения, которые могут играть ключевую роль при прогнозировании конкретного свойства. Совместное использование этих двух операций делает итоговое молекулярное представление более информативным:

$$h_G \in \mathbb{R}^{512}. \quad (3.16)$$

Такая размерность получается потому, что скрытое представление каждой вершины имеет размерность 256, а конкатенация среднего и максимального pooling удваивает её.

Полученный вектор h_G использовался как итоговое графовое представление молекулы и передавался в голову прогнозирования ADMET-свойств:

$$\hat{y} = F_{\text{pred}}(h_G), \quad (3.17)$$

где F_{pred} — нейронная сеть прогнозирования, а $\hat{y}$ — предсказанное значение целевого свойства.

3.5 Модель Mamba

Для обработки строкового представления молекул в работе использовалась Mamba-подобная модель. Если графовая модель рассматривает молекулу как набор атомов и связей, то Mamba работает с другой формой записи — со SMILES. В этом случае молекула представляется как последовательность токенов, и модель учится извлекать из неё полезные признаки, учитывая порядок токенов, локальные фрагменты строки и более дальние зависимости между её частями.

Сначала SMILES преобразовывалась в последовательность токенов:

$$s = (s_1, s_2, \dots, s_T),$$

где T — длина последовательности после токенизации. Каждый токен s_t сопоставлялся целочисленному индексу из словаря, после чего переводился в плотный вектор с помощью слоя эмбедингов:

$$x_t = \text{Emb}(s_t),$$

где $x_t \in \mathbb{R}^d$ — эмбединг токена, а d — размерность скрытого пространства. В данной работе использовалась достаточно компактная архитектура, поэтому размерность скрытого пространства была выбрана равной

$$d = 64.$$

Такой размерности достаточно для извлечения основных последовательностных признаков из SMILES, при этом модель остаётся сравнительно небольшой и менее склонной к переобучению.

Mamba относится к классу моделей, основанных на *selective state space models*, то есть на моделях пространства состояний [10]. Их важное преимущество состоит в том, что они позволяют эффективно работать с длинными входами. В отличие от self-attention, где вычислительная сложность обычно растёт квадратично с длиной последовательности, модели пространства состояний могут обрабатывать последовательность с линейной сложностью по

её длине. Для SMILES это важно, так как разные молекулы могут иметь строки существенно разной длины, особенно если структура содержит ветвления, циклы или стереохимические обозначения [8].

В общем виде модель пространства состояний последовательно обновляет скрытое состояние при чтении входных токенов. Для шага t это можно записать следующим образом:

$$h_t = A_t h_{t-1} + B_t x_t, \quad (3.18)$$

$$y_t = C_t h_t + D x_t, \quad (3.19)$$

где x_t — входной вектор текущего токена, h_t — скрытое состояние модели на шаге t , y_t — выходное представление для этого шага, а A_t , B_t , C_t и D — параметры соответствующих преобразований.

Интуитивно параметр A_t отвечает за то, какая часть предыдущего состояния h_{t-1} будет сохранена при переходе к следующему токenu. Параметр B_t задаёт, насколько сильно текущий вход x_t повлияет на новое состояние. Параметр C_t преобразует скрытое состояние в выходное представление, а член $D x_t$ добавляет прямой вклад текущего токена в выход. Благодаря такой схеме модель может постепенно накапливать информацию о ранее прочитанных токенах и использовать её при формировании представления текущей позиции.

Главная особенность Mamba по сравнению с классическими моделями пространства состояний заключается в том, на что делать упор и смотреть более внимательно при предсказании свойства. Параметры A_t , B_t и C_t могут зависеть от входного представления x_t . Иначе говоря, модель не использует одну и ту же динамику для всех токенов, а подбирает её под текущий вход:

$$A_t = f_A(x_t), \quad B_t = f_B(x_t), \quad C_t = f_C(x_t), \quad (3.20)$$

где f_A , f_B и f_C — обучаемые функции, формирующие параметры на основе текущего токена.

Для SMILES-строк такая избирательность особенно важна. Разные токены несут разную химическую информацию: одни обозначают атомы, другие — ветвления, замыкания циклов, заряды, ароматичность или стереохимию. Поэтому модели полезно уметь по-разному реагировать на разные типы токенов: часть информации сохранять, часть обновлять, а часть, наоборот, отбрасывать как менее значимую для дальнейшей обработки.

Один Mamba-подобный блок в данной архитектуре можно описать как последовательность нескольких операций:

1. входная проекция;
2. локальная depthwise-свёртка;
3. selective state space преобразование;
4. нелинейное преобразование;
5. выходная проекция;

6. остаточное соединение.

На первом этапе эмбединг токена проецируется во внутреннее пространство блока:

$$z_t = W_{\text{in}}x_t + b_{\text{in}}, \quad (3.21)$$

где W_{in} и b_{in} — обучаемые параметры входной проекции. Эта операция позволяет подготовить представление токена к дальнейшей обработке внутри свёрточного и state-space-механизма.

Затем применяется операция свёртка вдоль последовательности:

$$\tilde{z}_t = \text{DWConv}(z_{t-r}, \dots, z_t, \dots, z_{t+r}), \quad (3.22)$$

где r задаёт радиус локального окна. Такая свёртка отвечает за извлечение локальных зависимостей между соседними токенами. В SMILES это имеет понятный смысл: рядом стоящие токены часто образуют небольшие химически значимые фрагменты, например последовательности атомов, обозначения ветвлений, ароматические участки или элементы записи циклов.

После локальной свёртки используется механизм пространства состояний:

$$y_t = \text{SSM}(\tilde{z}_t), \quad (3.23)$$

где $\text{SSM}(\cdot)$ обозначает selective state space преобразование. Эта часть блока уже работает не только с локальным окружением, но и с более дальними зависимостями в последовательности. Для SMILES это важно, поскольку связанные между собой элементы структуры могут находиться в строке на значительном расстоянии друг от друга.

Далее результат преобразуется выходной линейной проекцией:

$$o_t = W_{\text{out}}y_t + b_{\text{out}}, \quad (3.24)$$

где W_{out} и b_{out} — обучаемые параметры выходного слоя блока.

Чтобы обучение было более устойчивым, а информация из предыдущих слоёв не терялась, использовалось остаточное соединение:

$$x_t^{(\ell+1)} = x_t^{(\ell)} + o_t^{(\ell)}, \quad (3.25)$$

где ℓ — номер слоя. Остаточные связи помогают обучать многослойные модели и уменьшают риск того, что при прохождении через несколько блоков представления токенов будут ухудшаться или терять важные признаки.

В данной работе применялась компактная Mamba-подобная модель, состоящая из двух последовательных слоёв:

$$L = 2. \quad (3.26)$$

Такой вариант был выбран как компромисс между выразительностью и вычислительной сложностью. С одной стороны, двух слоёв достаточно, чтобы модель могла извлекать как локальные, так и более дальние зависимости в

SMILES. С другой стороны, небольшая глубина снижает риск переобучения, что особенно важно при ограниченном объёме обучающих данных и требует меньшего количества итераций во время обучения, что критически важно во время обучения.

Так как SMILES-строки имеют разную длину, при формировании батчей они дополнялись специальными padding-токенами до общей длины. Однако такие токены не являются частью исходной молекулы, поэтому они не должны влиять на итоговое представление, поэтому использовалась маска.

После прохождения через Mamba-слои для каждого токена получалось скрытое представление:

$$H = (h_1, h_2, \dots, h_T), \quad (3.27)$$

где

$$h_t \in \mathbb{R}^{64}.$$

Чтобы получить один общий вектор для всей SMILES-строки, использовался masked mean pooling:

$$h_{\text{SMILES}} = \frac{\sum_{t=1}^T m_t h_t}{\sum_{t=1}^T m_t}. \quad (3.28)$$

То есть усреднение выполнялось только по реальным токенам, а padding-токены исключались из расчёта. Это позволяет корректно получать представления для молекул разной длины и не вносить искажения из-за технического дополнения последовательностей.

3.6 Transformer-модель

Для обработки строкового представления молекул в работе также использовалась Transformer-модель. Как и Mamba, она принимает на вход токенизированную SMILES-строку, однако обрабатывает её другим способом. Основой Transformer является механизм self-attention, который позволяет каждому токenu учитывать информацию обо всех остальных токенах последовательности. Для SMILES это особенно полезно, поскольку элементы, связанные с одной и той же частью молекулярной структуры, не всегда находятся рядом в строковой записи. Например, обозначения циклов, ветвлений или стереохимических фрагментов могут быть разнесены по последовательности [10].

На первом этапе исходная SMILES-строка преобразовывалась в последовательность токенов:

$$s = (s_1, s_2, \dots, s_T),$$

где T — длина последовательности после токенизации. Каждый токен s_t отображался в индекс словаря, а затем переводился в плотный вектор с помощью слоя эмбедингов:

$$x_t = \text{Emb}(s_t),$$

где $x_t \in \mathbb{R}^d$, а d — размерность эмбединга. После этого все токенные представления объединялись в матрицу:

$$X = [x_1, x_2, \dots, x_T] \in \mathbb{R}^{T \times d}.$$

Эта матрица является входом для последующих слоёв Transformer Encoder. В отличие от рекуррентных моделей, Transformer не обрабатывает токены строго последовательно. Поэтому сам по себе он не знает, в каком порядке токены расположены в строке. Чтобы добавить эту информацию, к токенным эмбедингам прибавлялись позиционные кодировки:

$$z_t = x_t + PE_t.$$

В данной работе использовались синусоидальные позиционные кодировки. Для позиции pos и индекса компоненты i они задаются следующим образом:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad (3.29)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right), \quad (3.30)$$

где d — размерность скрытого пространства. Такие кодировки позволяют модели учитывать положение токена в последовательности и при этом дают возможность работать со строками разной длины. Кроме того, синусоидальная форма помогает модели частично улавливать относительные расстояния между позициями.

Основным механизмом Transformer является self-attention [8]. Его можно описать как способ построить для каждого токена новое представление на основе всей последовательности. При этом модель сама определяет, какие токены важнее для текущей позиции, а какие можно учитывать слабее.

Для входной матрицы X вычисляются три набора представлений: запросы Q , ключи K и значения V :

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V, \quad (3.31)$$

где W_Q , W_K и W_V — обучаемые матрицы параметров. Запрос можно интерпретировать как то, какую информацию текущий токен ищет в последовательности. Ключ показывает, какая информация содержится в токене, а значение является тем представлением, которое будет передаваться дальше при агрегации.

Scaled dot-product attention вычисляется по формуле:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (3.32)$$

где d_k — размерность векторов ключей. Матрица QK^T содержит оценки сходства между всеми парами токенов. Чем выше такое сходство, тем больший вес соответствующий токен получает при формировании нового представления. Деление на $\sqrt{d_k}$ используется для стабилизации значений: без него скалярные произведения могут становиться слишком большими, что ухудшает работу функции softmax.

После применения softmax получаются attention-веса. Они показывают, насколько сильно каждая позиция должна учитывать остальные позиции последовательности. Именно за счёт этого self-attention позволяет напрямую связывать удалённые друг от друга токены. В случае SMILES это важно, например, для корректного учёта циклов, ветвлений, зарядов и стереохимических обозначений.

Также был реализован multi-head attention, то есть несколько attention-механизмов, работающих параллельно. Для каждой головы j вычислялись собственные запросы, ключи и значения:

$$Q_j = XW_Q^{(j)}, \quad K_j = XW_K^{(j)}, \quad V_j = XW_V^{(j)}.$$

Выход одной attention-головы задаётся выражением:

$$head_j = \text{Attention}(Q_j, K_j, V_j).$$

После этого результаты всех голов объединяются и проходят через выходную линейную проекцию:

$$\text{MultiHead}(X) = \text{Concat}(head_1, \dots, head_H)W_O, \quad (3.33)$$

где H — число attention-heads, а W_O — обучаемая матрица выходной проекции. В данной работе использовалось

$$H = 4$$

attention-heads. Несколько голов позволяют модели одновременно рассматривать разные типы зависимостей: одна голова может быть более чувствительна к локальным фрагментам, другая — к дальним связям, третья — к токенам ветвлений или циклов. На практике это делает представление SMILES более гибким и информативным.

Transformer Encoder состоит из нескольких одинаковых слоёв. Каждый такой слой включает два основных подблока:

1. multi-head self-attention;
2. позиционно-независимую feed-forward сеть.

После каждого подблока применяются остаточное соединение и нормализация. Для блока self-attention это можно записать так:

$$\tilde{X}^{(\ell)} = \text{LayerNorm} \left(X^{(\ell)} + \text{MultiHead} \left(X^{(\ell)} \right) \right), \quad (3.34)$$

где $X^{(\ell)}$ — вход ℓ -го слоя, а $\tilde{X}^{(\ell)}$ — промежуточное представление после применения self-attention.

Затем к каждому токenu независимо применяется feed-forward сеть:

$$\text{FFN}(x) = W_2 \sigma(W_1 x + b_1) + b_2, \quad (3.35)$$

где W_1, W_2, b_1 и b_2 — обучаемые параметры, а σ — нелинейная функция активации. Хотя этот блок применяется отдельно к каждой позиции, параметры сети одинаковы для всех токенов. Это позволяет одинаковым образом преобразовывать признаки на разных позициях последовательности. В данной работе размерность внутреннего слоя feed-forward сети составляла

$$d_{\text{ff}} = 512.$$

Выход полного слоя Transformer Encoder после feed-forward блока имеет вид:

$$X^{(\ell+1)} = \text{LayerNorm} \left(\tilde{X}^{(\ell)} + \text{FFN} \left(\tilde{X}^{(\ell)} \right) \right). \quad (3.36)$$

Остаточные соединения помогают сохранять информацию из предыдущих слоёв и делают обучение более устойчивым. LayerNorm, в свою очередь, стабилизирует распределение скрытых представлений и обычно ускоряет сходимость модели.

В работе использовался Transformer Encoder с параметрами:

$$L = 4, \quad H = 4, \quad d_{\text{ff}} = 512.$$

Такая конфигурация является умеренной по размеру: модель достаточно выразительна для обработки SMILES-последовательностей, но при этом не становится излишне тяжёлой с точки зрения вычислений.

Поскольку SMILES-строки имеют разную длину, при формировании батчей короткие последовательности дополнялись специальными токенами. Однако эти токены добавляются только технически и не несут химической информации. Поэтому при вычислениях использовалась маска.

Маска применялась в self-attention, чтобы padding-позиции не участвовали в расчёте attention-весов как полноценные элементы последовательности. Это особенно важно при работе с батчами, где длины SMILES могут заметно отличаться.

После прохождения через L слоёв Transformer Encoder получалась матрица итоговых скрытых представлений:

$$H = [h_1, h_2, \dots, h_T],$$

где h_t — представление токена s_t после всех слоёв модели. Для получения одного общего вектора, описывающего всю молекулу, использовался masked mean pooling:

$$h_{\text{SMILES}} = \frac{\sum_{t=1}^T m_t h_t}{\sum_{t=1}^T m_t}. \quad (3.37)$$

Такое усреднение выполняется только по реальным токенам и исключает padding-токены из итогового представления. В результате модель получает корректный вектор даже для последовательностей разной длины.

3.7 Сравнение размеров моделей

Количество обучаемых параметров является важным показателем сложности модели. Чем больше параметров, тем выше потенциальная выразительность модели, но тем выше риск переобучения и вычислительная стоимость.

Таблица 1 — Сравнение используемых моделей

Модель	Представление молекулы	Тип архитектуры
MorganMLP	Morgan fingerprint	Полносвязная сеть
SmilesCNN	SMILES	Сверточная сеть
GINE	Молекулярный граф	Графовая нейронная сеть
Mamba	SMILES	Модель пространства состояний
Transformer	SMILES	Self-attention модель

Наиболее сложной по структуре является графовая модель GINE, поскольку она содержит несколько слоёв передачи сообщений и дополнительные декодеры для предобучения. Transformer также имеет значительное число параметров из-за многоголового внимания и feed-forward блоков. Модели MorganMLP и SmilesCNN являются более простыми и быстрыми в обучении.

ГЛАВА 4

ПРЕДОБУЧЕНИЕ МОДЕЛЕЙ

4.1 Общая идея предобучения

Предобучение моделей является одним из распространённых подходов при решении задач, в которых количество размеченных данных ограничено. В области молекулярного машинного обучения это особенно актуально, так как получение экспериментальных ADMET-характеристик требует значительных временных и финансовых затрат. При этом существует большое количество неразмеченных молекулярных данных, которые можно использовать для предварительного обучения моделей.

Основная идея предобучения заключается в том, что модель сначала обучается решать некоторую вспомогательную задачу на большом наборе молекул. Такая задача не обязательно совпадает с конечной задачей, однако она должна помогать модели выделять полезные закономерности в структуре молекул. После этого полученные веса используются как начальная инициализация для дообучения на конкретных ADMET-задачах. За счёт этого модель уже обладает некоторым базовым представлением о молекулах и может лучше обобщать информацию на малых выборках.

В данной работе для разных архитектур использовались различные стратегии предобучения, так как каждая модель работает с молекулярными данными в своём формате. Для графовой модели GINE применялись маскирование атомных признаков и реконструкция Morgan fingerprint. Для модели Mamba использовалось контрастивное обучение на аугментированных SMILES-строках. Для Transformer применялось маскированное языковое моделирование с дополнительным предсказанием физико-химических свойств молекулы [16].

Таким образом, в работе рассматривались следующие схемы предобучения:

1. GINE — маскирование атомных признаков и реконструкция Morgan fingerprint;
2. Mamba — контрастивное обучение на аугментированных SMILES;
3. Transformer — маскированное обучение с дополнительным предсказанием свойств молекулы.

4.2 Предобучение GINE

Для модели GINE использовалась схема самообучения, в которой были объединены локальная и глобальная цели. Такой подход позволяет модели

учитывать как информацию об отдельных атомах, так и информацию о молекуле в целом.

На локальном уровне выполнялось маскирование части атомов. Для каждой молекулы случайно выбирались атомы с вероятностью 15%, после чего их признаки скрывались от модели. Затем модель должна была восстановить исходные признаки замаскированных атомов на основе информации о соседних вершинах и структуре графа. Данная задача похожа на *masked language modeling*, но применяется не к токенам последовательности, а к вершинам молекулярного графа [11].

Пусть M — множество замаскированных вершин. Тогда функция потерь для восстановления атомных признаков имеет вид:

$$\mathcal{L}_{node} = \sum_{v \in M} \ell(\hat{x}_v, x_v), \quad (4.1)$$

где x_v — исходные признаки вершины v , $\hat{x}_v$ — предсказанные моделью признаки, а ℓ — функция ошибки для отдельной вершины. Так как атомные признаки могут иметь разную природу, функция ℓ объединяет несколько типов потерь: кросс-энтропию для категориальных признаков, *binary cross-entropy* для бинарных признаков и *Smooth L1 Loss* для непрерывных признаков.

Кроме локальной задачи, использовалась также глобальная цель. На основе итогового графового представления модель предсказывала молекулы *Morgan fingerprint*. *Morgan fingerprint* является распространённым способом описания молекулярной структуры в виде бинарного вектора, отражающего наличие определённых подструктур. Для этой задачи применялась функция потерь *BCEWithLogits*:

$$\mathcal{L}_{fp} = \text{BCEWithLogits}(\hat{f}, f), \quad (4.2)$$

где f — истинный *fingerprint* молекулы, а $\hat{f}$ — предсказание модели.

Итоговая функция потерь для предобучения GINE представляла собой взвешенную сумму локальной и глобальной ошибок:

$$\mathcal{L}_{GINE} = \lambda_{node} \mathcal{L}_{node} + \lambda_{fp} \mathcal{L}_{fp}. \quad (4.3)$$

В проведённых экспериментах использовались значения $\lambda_{node} = 1$ и $\lambda_{fp} = 1$. Это означает, что обе части функции потерь имели одинаковый вес. Такой выбор позволяет одновременно обучать модель восстанавливать локальные атомные признаки и учитывать глобальные структурные особенности молекулы.

4.3 Предобучение Mamba

Для модели Mamba использовалось контрастивное обучение. Данный подход основан на том, что разные представления одной и той же молекулы

должны находиться близко друг к другу в латентном пространстве, а представления разных молекул, наоборот, должны быть более различимыми.

В качестве разных представлений одной молекулы использовались аугментированные SMILES-строки. Одна и та же молекула может быть записана несколькими корректными SMILES-строками, так как порядок обхода атомов может отличаться. Поэтому для каждой молекулы формировались две аугментированные SMILES-записи, которые рассматривались как положительная пара. Остальные молекулы в мини-батче использовались как отрицательные примеры.

Пусть $z_i^{(1)}$ и $z_i^{(2)}$ — нормированные векторные представления двух аугментаций i -й молекулы. Тогда матрица сходства между представлениями вычислялась следующим образом:

$$S_{ij} = \frac{(z_i^{(1)})^T z_j^{(2)}}{\tau}, \quad (4.4)$$

где τ — температурный параметр, который регулирует резкость распределения вероятностей. Чем меньше значение τ , тем сильнее модель штрафует за близость отрицательных примеров к положительным.

Для направления $1 \rightarrow 2$ использовалась функция потерь NT-Xent:

$$\mathcal{L}_{1 \rightarrow 2} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(S_{ii})}{\sum_{j=1}^B \exp(S_{ij})}, \quad (4.5)$$

где B — размер мини-батча. В данной формуле числитель соответствует сходству положительной пары, а знаменатель содержит сходства со всеми объектами во второй группе представлений.

Для того чтобы обучение было симметричным, дополнительно вычислялась аналогичная функция потерь для направления $2 \rightarrow 1$. Итоговая функция потерь имела вид:

$$\mathcal{L}_{contrastive} = \frac{1}{2} (\mathcal{L}_{1 \rightarrow 2} + \mathcal{L}_{2 \rightarrow 1}). \quad (4.6)$$

Таким образом, контрастивное предобучение заставляет модель формировать близкие представления для разных SMILES-записей одной молекулы. Это делает модель менее чувствительной к конкретному способу записи SMILES и помогает ей лучше выделять химически значимую информацию.

4.4 Предобучение Transformer

Для модели Transformer использовалось предобучение на основе двух задач: masked language modeling и предсказания физико-химических свойств молекулы. Такой подход позволяет модели одновременно разобраться как

устроена структура SMILES-строки и какими характеристиками обладают молекулы.

Основной задачей являлось masked language modeling. В этой задаче случайно выбирались 15% токенов входной SMILES-строки, после чего они заменялись специальным токеном `<mask>`. Модель должна была по оставшемуся контексту восстановить исходные токены. Данная задача хорошо подходит для Transformer, так как архитектура способна учитывать взаимосвязи между токенами последовательности [18].

Функция потерь для masked language modeling записывается следующим образом:

$$\mathcal{L}_{MLM} = - \sum_{i \in M} \log p(t_i | s_M), \quad (4.7)$$

где M — множество замаскированных позиций, t_i — истинный токен в позиции i , а s_M — входная последовательность с замаскированными токенами.

Дополнительно для каждой молекулы рассчитывались физико-химические свойства: logP, TPSA и молекулярная масса. Эти значения предварительно стандартизировались и использовались как вспомогательные цели. Ошибка предсказания свойств вычислялась как среднеквадратичная ошибка:

$$\mathcal{L}_{prop} = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k - p_k)^2, \quad (4.8)$$

где K — число предсказываемых свойств, p_k — истинное значение свойства, а $\hat{p}_k$ — предсказанное значение.

Итоговая функция потерь для Transformer имела вид:

$$\mathcal{L}_{Transformer} = \mathcal{L}_{MLM} + 0.2\mathcal{L}_{prop}. \quad (4.9)$$

Коэффициент 0.2 перед $\mathcal{L}_{prop}$ использовался для балансировки вкладов двух задач. Основной задачей в данном случае является MLM, так как именно она формирует контекстные представления SMILES-последовательностей. Предсказание свойств играет роль дополнительного обучающего сигнала и помогает учитывать физико-химические особенности молекулы.

Также важно учитывать, что $\mathcal{L}_{MLM}$ и $\mathcal{L}_{prop}$ могут иметь разные масштабы значений и градиентов. Если не уменьшать вклад ошибки предсказания свойств, она может начать доминировать в общей функции потерь. Поэтому коэффициент 0.2 был выбран как эмпирический гиперпараметр, который позволяет использовать задачу предсказания свойств как регуляризирующую, но при этом сохранять приоритет masked language modeling.

4.5 Параметры оптимизации

Обучение моделей выполнялось с использованием оптимизатора AdamW. Он является модификацией Adam и отличается тем, что регуляризация весов через weight decay учитывается более корректно. AdamW часто применяется при обучении нейронных сетей, так как сочетает адаптивный выбор шага оптимизации и контроль величины параметров модели.

Для разных архитектур использовались близкие значения скорости обучения. Для GINe скорость обучения была выбрана равной $3 \cdot 10^{-4}$, а коэффициент weight decay составлял 10^{-4} . Для Mamba и Transformer использовалась такая же скорость обучения $3 \cdot 10^{-4}$, однако weight decay был увеличен до 10^{-2} . Более высокое значение регуляризации для последовательностных моделей связано с тем, что они имеют большее число параметров и, следовательно, сильнее подвержены переобучению.

Для повышения устойчивости обучения применялось ограничение нормы градиента:

$$\|g\|_2 \leq 1. \quad (4.10)$$

Ограничение нормы градиента позволяет избежать слишком больших обновлений параметров. Это особенно важно для глубоких моделей, таких как Transformer и Mamba, где в процессе обучения могут возникать резкие скачки градиентов.

Кроме того, в экспериментах использовались планировщики скорости обучения CosineAnnealingLR и OneCycleLR. Они позволяют изменять learning rate в процессе обучения. В начале обучение может выполняться с более крупным шагом, что ускоряет поиск хорошей области параметров, а к концу шаг уменьшается, что способствует более плавной сходимости. В целом выбранные параметры оптимизации обеспечивали сопоставимые условия обучения для разных архитектур.

ГЛАВА 5

ДООБУЧЕНИЕ МОДЕЛЕЙ И ОЦЕНКА КАЧЕСТВА

5.1 Процедура дообучения

После этапа предобучения модели дообучались для предсказания ADMET-свойств. Для каждой комбинации «модель–задача» рассматривались два варианта инициализации: использование весов, полученных на этапе предобучения, и случайная инициализация параметров. Каждая модель дообучалась под каждую задачу.

В задачах бинарной классификации в качестве функции потерь использовалась бинарная кросс-энтропия с логитами. Для регрессионных задач применялась функция потерь Smooth L1 Loss. Данная функция является более устойчивой к выбросам по сравнению со среднеквадратичной ошибкой, что особенно важно при работе с экспериментальными данными, где могут присутствовать шум и аномальные значения. Оптимизация параметров осуществлялась с помощью алгоритма AdamW. Скорость обучения была равна 10^{-4} , а коэффициент регуляризации weight decay также составлял 10^{-4} .

Для контроля переобучения использовалась ранняя остановка по валидационной метрике. Для классификационных задач отслеживался ROC-AUC, для регрессионных задач — MAE или Spearman в зависимости от используемого протокола оценки. Обучение прекращалось, если метрика не улучшалась в течение 15 эпох. В итоговое тестирование передавались веса модели с наилучшим значением на валидационной выборке. В качестве итоговой сохранялась та версия модели, которая показала наилучшее качество на валидационных данных.

5.2 Метрики качества для задач классификации

Для задач бинарной классификации основной метрикой качества была выбрана ROC-AUC. Данная метрика характеризует способность модели правильно ранжировать объекты, то есть присваивать объектам положительного класса более высокие значения предсказаний по сравнению с объектами отрицательного класса. Важным преимуществом ROC-AUC является то, что она не зависит от выбора конкретного порога классификации, поэтому хорошо подходит для сравнения различных моделей.

ROC-кривая строится на основе значений TPR и FPR , вычисленных при различных порогах классификации. Величина TPR (true positive rate) показывает долю объектов положительного класса, которые были корректно отнесены моделью к положительному классу. Эта величина также называется

полнотой или чувствительностью:

$$TPR = \frac{TP}{TP + FN}, \quad (5.1)$$

где TP — количество истинно положительных предсказаний, а FN — количество ложно отрицательных предсказаний.

Величина FPR (false positive rate) показывает долю объектов отрицательного класса, которые модель ошибочно классифицировала как положительные:

$$FPR = \frac{FP}{FP + TN}, \quad (5.2)$$

где FP — количество ложно положительных предсказаний, а TN — количество истинно отрицательных предсказаний.

Таким образом, ROC-AUC определяется как площадь под ROC-кривой:

$$ROC-AUC = \int_0^1 TPR(FPR) dFPR. \quad (5.3)$$

Помимо ROC-AUC, для оценки качества классификационных моделей использовалась метрика AP (average precision). Она связана с площадью под precision–recall кривой и особенно полезна в случаях, когда классы в выборке несбалансированы. Это актуально для многих ADMET-задач, поскольку положительный класс может встречаться существенно реже отрицательного.

Точность (*Precision*) показывает, какая часть объектов, отнесённых моделью к положительному классу, действительно принадлежит к этому классу:

$$Precision = \frac{TP}{TP + FP}. \quad (5.4)$$

Полнота (*Recall*) совпадает с TPR и отражает долю объектов положительного класса, которые модель смогла обнаружить:

$$Recall = \frac{TP}{TP + FN}. \quad (5.5)$$

Метрика AP представляет собой усреднение значений точности по различным уровням полноты. В дискретном виде она может быть записана следующим образом:

$$AP = \sum_n (R_n - R_{n-1}) P_n, \quad (5.6)$$

где P_n и R_n — значения precision и recall, соответствующие n -му порогу классификации.

Таким образом, ROC-AUC позволяет оценить общее качество ранжирования объектов моделью, тогда как AP дополнительно показывает, насколько хорошо модель выделяет объекты положительного класса. Это особенно важно в задачах с выраженным дисбалансом классов.

5.3 Метрики качества для задач регрессии

Для регрессионных задач основной метрикой качества была выбрана средняя абсолютная ошибка MAE. Она показывает среднее абсолютное отклонение предсказанных значений от истинных:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (5.7)$$

где y_i — истинное значение целевой переменной для i -го объекта, $\hat{y}_i$ — соответствующее предсказанное значение, а n — общее число объектов в выборке. Чем меньше значение MAE, тем ближе предсказания модели к истинным значениям и тем выше качество решения регрессионной задачи.

Дополнительно для анализа результатов использовался коэффициент ранговой корреляции Спирмена. В отличие от MAE, данная метрика оценивает не величину ошибки в исходных значениях, а способность модели сохранять правильный порядок объектов по целевой переменной. Это может быть важно в прикладных задачах, где требуется не только получить точное численное значение, но и корректно упорядочить соединения по степени выраженности рассматриваемого свойства.

Коэффициент Спирмена вычисляется по формуле:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad (5.8)$$

где d_i — разность между рангами истинного и предсказанного значения для i -го объекта.

Значение коэффициента ρ лежит в диапазоне от -1 до 1 . Если ρ близок к 1 , это означает, что модель хорошо сохраняет порядок объектов. Значения, близкие к 0 , указывают на отсутствие выраженной ранговой зависимости между истинными и предсказанными значениями. Отрицательные значения коэффициента свидетельствуют об обратной зависимости между рангами.

ГЛАВА 6

АНАЛИЗ ЭКСПЕРИМЕНТАЛЬНЫХ РЕЗУЛЬТАТОВ

6.1 Общая характеристика результатов

Проведённые эксперименты показали, что качество модели существенно зависит как от архитектуры, так и от типа прогнозируемого ADMET-свойства. Универсально лучшей модели для всех задач нет, что согласуется с природой ADMET: разные свойства определяются различными химическими факторами.

Задачи, связанные с локальными структурными мотивами, достаточно хорошо решаются с использованием Morgan fingerprints и MLP. В то же время задачи, где важна топология молекулы, могут выигрывать от применения графовых нейронных сетей.

6.2 Результаты по задачам всасывания

К группе всасывания относятся Caco2, HIA, Pgp, Bioavailability, Solubility и Lipophilicity. Эти свойства связаны с проницаемостью, растворимостью, липофильностью и взаимодействием с транспортёрами.

Для классификационных задач HIA, Pgp и Bioavailability использовалась ROC-AUC. Для регрессионных задач Caco2, Lipophilicity и Solubility использовалась MAE. На рисунке 6.1 представлены результаты моделей на задачах группы всасывания.

По результатам задач группы всасывания видно, что универсально лучшей модели для всех свойств не наблюдается. GINE показывает наилучшие результаты на Caco2 (0.573 по Spearman) и Pgp (0.893 по ROC-AUC), что указывает на высокую информативность графового представления молекулярной структуры для задач, связанных с проницаемостью и взаимодействием с транспортёрами. В задаче HIA лучший результат достигает Transformer (0.879 ROC-AUC), при этом GINE (0.850) и Mamba (0.812) также демонстрируют близкое качество.

Для Bioavailability лидирует Mamba со значением ROC-AUC 0.691, однако Transformer (0.684) и GINE (0.669) отстают незначительно. В целом наиболее стабильными среди рассмотренных подходов выглядят GINE и последовательностные модели Transformer/Mamba, тогда как SmilesCNN и MorganMLP чаще уступают лидерам, за исключением задачи Pgp, где модель MorganMLP показывает конкурентоспособный результат (0.870 ROC-AUC).




Рисунок 6.1 — Результаты моделей на задачах группы всасывания. Для Caco2 показана метрика Spearman, для HIA, Pgp и Bioavailability — ROC-AUC. Лучший результат на каждом датасете выделен тёмным цветом.

6.3 Результаты по задачам распределения

К группе распределения относятся BBB, PPBR и VDss. Эти свойства описывают способность молекулы проникать через гематоэнцефалический барьер, связываться с белками плазмы и распределяться в тканях.

BBB является задачей бинарной классификации. Для неё важны липофильность, размер молекулы, полярная поверхность и наличие ионизируемых групп. Поэтому модели, способные учитывать как локальные фрагменты, так и глобальные свойства, имеют преимущество.

PPBR и VDss являются регрессионными задачами. Их прогнозирование сложнее, поскольку экспериментальные значения могут иметь значительную вариативность и зависеть от множества факторов.

На рисунке 6.2 представлены результаты моделей на задачах группы распределения. Для задачи BBB наилучшее качество показала модель GINE со значением ROC-AUC 0.922. Это указывает на то, что графовое представление молекулы эффективно отражает структурные признаки, важные для проникновения через гематоэнцефалический барьер. Также высокое качество показали MorganMLP (0.873) и SmilesCNN (0.827). Модели Transformer и Mamba получили более низкие, но всё ещё достаточно хорошие значения ROC-AUC: 0.780 и 0.773 соответственно.

Для регрессионной задачи PPBR лучшей оказалась модель Transformer со значением Spearman 0.374. Остальные модели заметно уступают: GINE достигает 0.206, MorganMLP — 0.122, Mamba — 0.100, а SmilesCNN — 0.088. Это говорит о том, что связывание с белками плазмы является более сложным для прогнозирования свойством, и в данной задаче преимущество имеет мо-




Рисунок 6.2 — Результаты моделей на задачах группы распределения. Для BBB показана метрика ROC-AUC, для PPBR и VDss — Spearman. Лучший результат для каждой задачи выделен тёмным цветом.

дель, способная учитывать более дальние зависимости в последовательном представлении молекулы.

В задаче VDss лучший результат снова показывает GINE со значением Spearman 0.626. Mamba и Transformer занимают второе и третье места со значениями 0.480 и 0.464 соответственно. SmilesCNN показывает умеренное качество (0.337), тогда как MorganMLP значительно уступает остальным моделям (0.134). Таким образом, в группе распределения GINE является наиболее сильной моделью для BBB и VDss, тогда как для PPBR лучший результат достигается Transformer. В целом результаты подтверждают, что разные свойства распределения требуют различных типов молекулярного представления.

6.4 Результаты по задачам метаболизма

Задачи метаболизма включают ингибирование ферментов CYP и субстратность. Эти задачи имеют важное значение для оценки риска лекарственных взаимодействий.

На рисунке 6.3 представлены результаты моделей на задачах метаболизма. В задачах ингибирования ферментов CYP наиболее стабильные результаты показывает GINE: эта модель занимает первое место для CYP1A2_Inhib (0.932), CYP2C9_Inhib (0.891), CYP2C19_Inhib (0.888), CYP2D6_Inhib (0.860) и CYP3A4_Inhib (0.889). При этом MorganMLP также демонстрирует близкие значения на большинстве задач ингибирования, например 0.908 для задачи CYP1A2_Inhib и 0.874 для CYP3A4_Inhib. Это показывает, что для предсказания ингибирования CYP-ферментов важную роль играют как графовая структура молекулы, так и молекулярные отпечатки.

Для задач субстратности результаты менее однородны. Например, в задаче CYP2C9_Substrate лучшей моделью является SmilesCNN со значением ROC-AUC 0.692, тогда как Mamba и GINE показывают близкие результаты 0.627 и 0.619. В задаче CYP2D6_Substrate лидирует GINE с ROC-AUC 0.861, заметно превосходя SmilesCNN (0.778) и MorganMLP (0.720). Для CYP3A4_Substrate лучший результат показывает MorganMLP (0.704), далее следуют GINE (0.636) и Transformer (0.628). В целом задачи ингибирования




Рисунок 6.3 — Результаты моделей на задачах группы метаболизма. Для всех задач используется метрика ROC-AUC. Лучший результат для каждой задачи выделен тёмным цветом.

решаются моделями лучше, чем задачи субстратности, а наиболее устойчивой моделью в группе метаболизма является GINE.

6.5 Результаты по задачам вывода

К задачам вывода относятся Half-Life, Clearance Hepatocyte и Clearance Microsome. Эти свойства являются регрессионными и отражают скорость удаления соединения из организма.

На рисунке 6.4 представлены результаты моделей на задачах вывода. Для Clearance_Hepatocyte лучший результат показывает Transformer со значением Spearman 0.173, однако в целом качество моделей на этой задаче остаётся низким: GINE достигает 0.129, а MorganMLP, SmilesCNN и Mamba дают отрицательные значения корреляции (-0.017 , -0.054 и -0.155 соответственно). Это указывает на сложность предсказания клиренса в гепатоцитах и слабую выраженность зависимостей, которые модели смогли извлечь из молекулярных представлений.

Для Clearance_Microsome и Half_Life наилучшие результаты показывает GINE. В задаче Clearance_Microsome значение Spearman составляет 0.402,




Рисунок 6.4 — Результаты моделей на задачах группы выведения. Для всех задач используется метрика Spearman. Лучший результат для каждой задачи выделен тёмным цветом.

что заметно выше результата Transformer (0.237), тогда как остальные модели имеют значения около нуля или ниже. В задаче Half_Life GINE также лидирует со значением 0.294, далее следуют Transformer (0.207) и Mamba (0.183), в то время как SmilesCNN и MorganMLP показывают отрицательную корреляцию. В целом задачи выведения оказываются наиболее сложными среди рассмотренных групп: даже лучшие значения Spearman остаются умеренными, а наиболее устойчивыми моделями являются GINE и Transformer.

6.6 Результаты по токсичности

В работе рассматривались задачи LD50 и hERG. LD50 является регрессионной задачей оценки острой токсичности, а hERG — задачей бинарной классификации кардиотоксического риска.

hERG является особенно важной задачей, поскольку ингибирование hERG-канала может приводить к нарушениям сердечного ритма. Для этой задачи важны как локальные фармакофорные мотивы, так и глобальные свойства молекулы.

На рисунке 6.5 представлены результаты моделей на задачах токсичности. Для задачи hERG лучший результат показывает GINE со значением ROC-AUC 0.881, заметно превосходя MorganMLP (0.794), SmilesCNN (0.764), Mamba (0.704) и Transformer (0.612). Это указывает на то, что графовое представление молекулы наиболее эффективно учитывает структурные особенности, связанные с риском ингибирования hERG-канала. Для регрессионной задачи LD50 GINE также занимает первое место со значением Spearman 0.656, за ней следуют SmilesCNN (0.602), MorganMLP (0.573), Transformer (0.564) и Mamba (0.486).

По задачам токсичности наиболее устойчивой моделью является GINE, которая показывает лучшие результаты как для классификационной задачи hERG, так и для регрессионной задачи LD50. Дополнительно на рисунке приведены результаты для AqSol и Lipo: в обеих задачах GINE также лидирует со значениями Spearman 0.774 и 0.727 соответственно. Это подтверждает, что графовые представления хорошо подходят для предсказания свойств, завися-




Рисунок 6.5 — Результаты моделей на задачах токсичности. Для hERG используется метрика ROC-AUC, для LD50 — Spearman. Дополнительно на рисунке приведены результаты для задач AqSol и Lipo. Лучший результат для каждой задачи выделен тёмным цветом.

щих от молекулярной структуры и физико-химических характеристик.

6.7 Распределение побед моделей

Для обобщённого анализа было подсчитано количество задач, на которых каждая модель показала лучший результат. Подсчёт числа побед использовался как дополнительная сводная характеристика. Он не заменяет анализ значений метрик, но показывает, насколько часто модель оказывается лучшей при переходе от одной группы ADMET-задач к другой.

На рисунке 6.6 показано распределение числа задач, на которых каждая модель заняла первое место. Наиболее выраженное преимущество имеет GINE: данная модель показала лучший результат на 16 задачах. Это значительно больше, чем у остальных подходов, и указывает на высокую универсальность графового представления молекулы для широкого набора ADMET-свойств. Такой результат согласуется с предыдущими разделами, где GINE часто лидировала в задачах всасывания, распределения, метаболизма, выведения и токсичности.

Второе место занимает Transformer, который оказался лучшим на 3 задачах. Остальные модели имеют по одной победе: Mamba, MorganMLP и SmilesCNN выиграли по 1 задаче каждая. Это говорит о том, что данные подходы могут быть полезны для отдельных типов свойств, однако в целом уступают GINE по устойчивости. Таким образом, итоговое распределение побед подтверждает, что наиболее надёжной и универсальной моделью в проведённых экспериментах является GINE, тогда как последовательностные и




Рисунок 6.6 — Распределение числа побед моделей на задачах ADMET. Победой считается лучший результат модели на отдельной задаче.

fingerprint-based модели проявляют скорее специализированные преимущества.

ГЛАВА 7

СРАВНЕНИЕ С ПУБЛИЧНЫМИ РЕЗУЛЬТАТАМИ

7.1 Цель сравнения

Для оценки практической значимости полученных результатов было выполнено сравнение модели GINE, показавшей лучшие результаты среди реализованных моделей, с известными публичными результатами на датасете ADMET. В качестве внешнего ориентира использовались лучшие опубликованные значения для каждой из задач.

Такое сравнение не является полностью строгим в случае отличий в протоколах обучения, числе эпох, гиперпараметрах и вариантах разбиения данных. Однако оно позволяет понять, насколько разработанная модель приближается к уровню специализированных решений.

7.2 Сопоставление метрик

Для разных задач использовались разные метрики: ROC-AUC, AUPRC, MAE и Spearman. При сравнении необходимо учитывать направление оптимизации. Для ROC-AUC, AUPRC и Spearman большее значение означает лучший результат. Для MAE меньшее значение означает лучший результат.

Разность между результатом GINE и публичным лучшим результатом вычислялась как:

$$\Delta = S_{GINE} - S_{public}. \quad (7.1)$$

Для метрик, где больше — лучше, положительное значение Δ означает превосходство GINE. Для MAE, наоборот, отрицательное значение указывает на лучший результат GINE.

7.3 Интерпретация сравнения

На рисунке 7.1 представлено сравнение качества модели GINE с лучшими публично доступными моделями на наборе ADMET-задач. В таблице приведены название задачи, категория, используемая метрика, лучшая публичная модель, её результат, а также результат GINE.

При интерпретации результатов важно учитывать направление оптимизации метрик. Для метрик `roc_auc`, `auprc` и `spearman` большее значение означает лучшее качество модели. Для метрики `mae`, наоборот, меньшее значение соответствует меньшей ошибке и, следовательно, лучшему результату.

model	bench_task	category	metric	public_best_model	public_best_score	gine_score
GINE	Solubility_AqSolDB	Absorption	mae	MiniMol	0.741	0.951
GINE	Bioavailability_Ma	Absorption	roc_auc	MiniMol	0.942	0.676
GINE	Caco2_Wang	Absorption	mae	CaliciBoost	0.256	0.319
GINE	HIA_Hou	Absorption	roc_auc	MiniMol	0.993	0.971
GINE	Lipophilicity_AstraZeneca	Absorption	mae	MiniMol	0.456	0.508
GINE	Pgp_Broccatelli	Absorption	roc_auc	MapLight + GNN	0.938	0.924
GINE	BBB_Martins	Distribution	roc_auc	MiniMol	0.924	0.921
GINE	PPBR_AZ	Distribution	mae	Gradient Boost	7.440	9.132
GINE	VDss_Lombardo	Distribution	spearman	MapLight + GNN	0.713	0.677
GINE	CYP2C9_Veith	Metabolism	auprc	MapLight + GNN	0.859	0.784
GINE	CYP2C9_Substrate_CarbonMangels	Metabolism	auprc	MiniMol	0.474	0.372
GINE	CYP2D6_Veith	Metabolism	auprc	MapLight + GNN	0.790	0.624
GINE	CYP2D6_Substrate_CarbonMangels	Metabolism	auprc	ContextPred	0.736	0.825
GINE	CYP3A4_Veith	Metabolism	auprc	MapLight + GNN	0.916	0.846
GINE	CYP3A4_Substrate_CarbonMangels	Metabolism	roc_auc	CFA	0.667	0.666
GINE	Clearance_Hepatocyte_AZ	Metabolism	spearman	CFA	0.536	0.574
GINE	Clearance_Microsome_AZ	Metabolism	spearman	MapLight + GNN	0.630	0.515
GINE	Half_Life_Obach	Metabolism	spearman	CFA	0.576	0.479
GINE	AMES	Toxicity	roc_auc	ZairaChem	0.871	0.840
GINE	DILI	Toxicity	roc_auc	MiniMol	0.956	0.863
GINE	LD50_Zhu	Toxicity	mae	BaseBoosting KyQVZ6b2	0.552	0.512
GINE	hERG	Toxicity	roc_auc	MapLight + GNN	0.880	0.875

Рисунок 7.1 — Сравнение результатов модели GINE с лучшими публичными моделями на задачах ADMET. Для метрик ROC-AUC, AUPRC и Spearman большее значение соответствует лучшему результату, тогда как для MAE лучшим является меньшее значение.

В целом GINE уступает лучшим публичным моделям на большинстве рассмотренных задач. Из представленных задач модель GINE показывает лучший результат только на трёх бенчмарках.

В категории *Absorption* модель GINE не превосходит лучшие публичные модели ни на одной задаче. На некоторых задачах разрыв является небольшим, например на HIA_Hou, где GINE получает ROC-AUC 0.971 против 0.993 у MiniMol, и на Pgp_Broccatelli, где результат GINE равен 0.924 против 0.938 у MapLight + GNN. Однако на задачах Bioavailability_Ma, Caco2_Wang, Lipophilicity_AstraZeneca и Solubility_AqSolDB отставание GINE более заметно.

В категории *Distribution* GINE также уступает лучшим публичным моделям на всех задачах. Наиболее близкий результат наблюдается на задаче BBB_Martins: ROC-AUC модели GINE составляет 0.921, тогда как у MiniMol он равен 0.924. На задаче VDss_Lombardo значение Spearman для GINE равно 0.677 против 0.713 у MapLight + GNN. На задаче PPBR_AZ GINE показывает более высокую ошибку MAE: 9.132 против 7.440 у Gradient Boost.

Наиболее успешной для GINE является категория *Metabolism*. Именно

здесь модель получает две из трёх побед. Также она демонстрирует почти равный результат на задаче CYP3A4_Substrate_CarbonMangels: ROC-AUC равен 0.666 против 0.667 у CFA. Тем не менее на ряде других задач метаболизма модель заметно уступает, например на CYP2D6_Veith (0.624 против 0.790 по AUPRC), CYP2C9_Substrate_CarbonMangels (0.372 против 0.474 по AUPRC) и Clearance_Microsome_AZ (0.515 против 0.630 по Spearman).

В категории *Toxicity* GINE превосходит публичный результат только на задаче LD50_Zhu, где используется метрика MAE. На остальных задачах токсичности модель уступает: для AMES ROC-AUC составляет 0.840 против 0.871, для DILI — 0.863 против 0.956, а для hERG — 0.875 против 0.880. При этом на задаче hERG разрыв минимален, что указывает на близкое качество моделей.

Таким образом, результаты на рисунке 7.1 показывают, что GINE не является лучшей моделью на большинстве ADMET-бенчмарков, однако демонстрирует конкурентоспособность на отдельных задачах, прежде всего в категории метаболизма. Наиболее сильные результаты GINE наблюдаются на задачах CYP2D6_Substrate_CarbonMangels, Clearance_Hepatocyte_AZ и LD50_Zhu, тогда как наиболее проблемными являются задачи абсорбции и некоторые задачи регрессии, оцениваемые по MAE.

ЗАКЛЮЧЕНИЕ

В работе исследованы нейронные модели для прогнозирования ADMET-свойств химических соединений. Были рассмотрены три типа молекулярных представлений: Morgan fingerprints, SMILES-последовательности и молекулярные графы. Для них реализованы пять моделей: MorganMLP, SmilesCNN, GINE, Mamba и Transformer.

Эксперименты проводились на задачах ADMET Benchmark из Therapeutics Data Commons. Для классификационных задач использовалась метрика ROC-AUC, для регрессионных задач — MAE и коэффициент ранговой корреляции Спирмена. Для большинства наборов данных применялось scaffold-разбиение, что позволило оценивать качество моделей на химических структурах, отличающихся от обучающих.

Наиболее устойчивые результаты среди реализованных моделей показала GINE. Она заняла первое место на 16 задачах из рассмотренного набора. Особенно заметным её преимущество оказалось в задачах ингибирования CYP-ферментов, BBB, VDss, hERG и LD50. Это показывает, что явное использование графовой структуры молекулы и признаков химических связей полезно для широкого круга ADMET-задач.

При этом результаты не позволяют считать графовый подход универсально лучшим. Для отдельных задач лучшие значения были получены последовательностными моделями или моделью на Morgan fingerprints. Например, Transformer показал лучший результат для PPBR, Mamba — для Bioavailability, а MorganMLP оказался лучшим для одной из задач субстратности. Следовательно, выбор архитектуры должен учитывать конкретное прогнозируемое свойство.

Сравнение GINE с публичными результатами ADMET Benchmark показало, что реализованная модель в большинстве случаев уступает лучшим опубликованным решениям, однако на отдельных задачах демонстрирует близкое или более высокое качество. Это говорит о том, что выбранная архитектура может рассматриваться как сильная базовая модель, но дальнейшее улучшение требует более тщательного подбора гиперпараметров, анализа влияния предобучения и расширения экспериментального протокола.

В дальнейшем работу можно развить в нескольких направлениях: провести несколько запусков с разными random seed и оценить устойчивость результатов; добавить multi-task обучение; объединить графовые, fingerprint- и SMILES-представления; использовать трёхмерные признаки молекул; а также применить методы интерпретации, позволяющие анализировать вклад отдельных атомов и фрагментов в предсказание модели.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Huang K., Fu T., Gao W. et al. Therapeutics Data Commons: Machine Learning Datasets and Tasks for Drug Discovery and Development // Proceedings of Neural Information Processing Systems. 2021.
2. Landrum G. RDKit: Open-source cheminformatics software. URL: <https://www.rdkit.org>.
3. Morgan H. L. The Generation of a Unique Machine Description for Chemical Structures — A Technique Developed at Chemical Abstracts Service // Journal of Chemical Documentation. 1965. Vol. 5, No. 2. P. 107–113.
4. Rogers D., Hahn M. Extended-Connectivity Fingerprints // Journal of Chemical Information and Modeling. 2010. Vol. 50, No. 5. P. 742–754.
5. Kipf T. N., Welling M. Semi-Supervised Classification with Graph Convolutional Networks // International Conference on Learning Representations. 2017.
6. Xu K., Hu W., Leskovec J., Jegelka S. How Powerful are Graph Neural Networks? // International Conference on Learning Representations. 2019.
7. Hu W., Liu B., Gomes J. et al. Strategies for Pre-training Graph Neural Networks // International Conference on Learning Representations. 2020.
8. Vaswani A., Shazeer N., Parmar N. et al. Attention Is All You Need // Advances in Neural Information Processing Systems. 2017.
9. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL-HLT. 2019.
10. Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. 2023.
11. Cherkasov A., Muratov E. N., Fourches D. et al. QSAR Modeling: Where Have You Been? Where Are You Going To? // Journal of Medicinal Chemistry. 2014. Vol. 57, No. 12. P. 4977–5010.
12. Wang Y., Xing J., Xu Y. et al. In Silico ADME/T Modelling for Rational Drug Design // Quarterly Reviews of Biophysics. 2015. Vol. 48, No. 4. P. 488–515.

13. Weininger D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules // Journal of Chemical Information and Computer Sciences. 1988. Vol. 28, No. 1. P. 31–36.
14. Ramsundar B., Eastman P., Walters P., Pande V. Deep Learning for the Life Sciences. O'Reilly Media, 2019.
15. Fabian B., Edlich T., Gaspar H. et al. Molecular Representation Learning with Language Models and Domain-Relevant Auxiliary Tasks. 2020.
16. Chithrananda S., Grand G., Ramsundar B. ChemBERTa: Large-Scale Self-Supervised Pretraining for Molecular Property Prediction. 2020.
17. Paszke A., Gross S., Massa F. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. 2019.
18. Fey M., Lenssen J. E. Fast Graph Representation Learning with PyTorch Geometric // ICLR Workshop on Representation Learning on Graphs and Manifolds. 2019.
19. Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. 2011. Vol. 12. P. 2825–2830.
20. Irwin J. J., Shoichet B. K. ZINC — A Free Database of Commercially Available Compounds for Virtual Screening // Journal of Chemical Information and Modeling. 2005. Vol. 45, No. 1. P. 177–182.