

РАЗРАБОТКА НЕЙРОННОЙ СЕТИ ДЛЯ ПРЕДСКАЗАНИЯ СВОЙСТВ ЛЕКАРСТВЕННО-ПОДОБНЫХ МОЛЕКУЛ

Благодарный Артём Андреевич

Научный руководитель:

доктор физико-математических наук, профессор
Тузиков Александр Васильевич

Цель данной дипломной работы - разработать нейронную сеть для предсказания лекарственно-подобных свойств молекул.


Для достижения цели решаются следующие **задачи**:

1. Подготовка мультимодального набора данных для обучения моделей;
2. Разработка и реализация 5 архитектур нейронных сетей;
3. Проведение предобучения моделей на неразмеченных данных;
4. Замер моделей на тестовых данных;
5. Сравнение и анализ полученных результатов.

Проблематика разработки лекарственных средств



10-15 лет на разработку



\$2,6 млрд средняя
стоимость одного препарата



90% кандидатов отсеиваются
на стадиях испытаний

Жизненный цикл лекарства: ADMEТ



- ▶ **Absorption** — попадание в кровоток
- ▶ **Distribution** — распределение по тканям
- ▶ **Metabolism** — биотрансформация
- ▶ **Excretion** — выведение из организма
- ▶ **Toxicity** — токсическое воздействие

Датасет



ADMET Group Leaderboard

TDC.Caco2_Wang	Leaderboard
TDC.Bioavailability_Ma	Leaderboard
TDC.Lipophilicity_AstraZeneca	Leaderboard
TDC.Solubility_AqSolDB	Leaderboard
TDC.HIA_Hou	Leaderboard
TDC.Pgp_Broccatelli	Leaderboard
TDC.BBB_Martins	Leaderboard
TDC.PPBR_AZ	Leaderboard
TDC.VDss_Lombardo	Leaderboard
TDC.CYP2C9_Veith	Leaderboard
TDC.CYP2D6_Veith	Leaderboard
TDC.CYP3A4_Veith	Leaderboard
TDC.CYP2C9_Substrate_CarbonMangels	Leaderboard
TDC.CYP2D6_Substrate_CarbonMangels	Leaderboard
TDC.CYP3A4_Substrate_CarbonMangels	Leaderboard
TDC.Half_Life_Obach	Leaderboard
TDC.Clearance_Hepatocyte_AZ	Leaderboard
TDC.Clearance_Microsome_AZ	Leaderboard
TDC.LD50_Zhu	Leaderboard
TDC.hERG	Leaderboard
TDC.AMES	Leaderboard
TDC.DILI	Leaderboard

TDC.Caco2_Wang Leaderboard


Dataset Summary

Dataset	Unit	Size	Task	Metric	Dataset Split
TDC.Caco2_Wang	cm/s	906	Regression	MAE	Scaffold


Leaderboard

Rank	Model	Contact	Link	#Params	MAE ↓
1	CaliciBoost	Weibin Ren	GitHub, Paper	N/A	0.256 ± 0.006
2	XG Boost	Rob Learsch	GitHub, Paper	21	0.274 ± 0.004
3	MapLight	Jim Notwell	GitHub, Paper	N/A	0.276 ± 0.005
4	BaseBoosting	Andrew Li	GitHub, Paper	365,713	0.285 ± 0.005
5	MolMapNet-D	Shen Wan Xiang	GitHub, Paper	407,617	0.287 ± 0.005
6	MapLight + GNN	Jim Notwell	GitHub, Paper	N/A	0.287 ± 0.005
7	XGBoost	Andrew Li	GitHub, Paper	12	0.289 ± 0.011
8	DeepMol (AutoML)	DeepMol team	GitHub, Paper	N/A	0.297 ± 0.008
9	Basic ML	Nilavo Boral	GitHub, Paper	N/A	0.321 ± 0.005
10	ADMETrix	Rohit Singh Yadav	GitHub, Paper	N/A	0.326 ± 0.042
11	Chemprop-RDKit	Kyle Swanson	GitHub, Paper	N/A	0.330 ± 0.024
12	CFA	Nan Jiang	GitHub, Paper	N/A	0.335 ± 0.033


Молекулярное представление



SMILES-строка




Morgan Fingerprints



Молекулярный граф


Morgan + MLP

```
MorganMLP(  
  (net): Sequential(  
    (0): Linear(in_features=1024, out_features=1024, bias=True)  
    (1): ReLU()  
    (2): Dropout(p=0.1, inplace=False)  
    (3): Linear(in_features=1024, out_features=512, bias=True)  
    (4): ReLU()  
    (5): Dropout(p=0.1, inplace=False)  
    (6): Linear(in_features=512, out_features=128, bias=True)  
    (7): ReLU()  
    (8): Linear(in_features=128, out_features=1, bias=True)  
  )  
)
```




SMILES + CNN

```
SmilesCNN(
  (embedding): Embedding(64, 64, padding_idx=0)
  (conv1): Conv1d(64, 32, kernel_size=(4,), stride=(1,))
  (conv2): Conv1d(32, 64, kernel_size=(6,), stride=(1,))
  (conv3): Conv1d(64, 96, kernel_size=(8,), stride=(1,))
  (mlp): Sequential(
    (0): Linear(in_features=96, out_features=32, bias=True)
    (1): ReLU()
    (2): Linear(in_features=32, out_features=32, bias=True)
    (3): Linear(in_features=32, out_features=1, bias=True)
  )
)
```





Conv1d



GINE




Mamba



Transformer



Размеры моделей



Метрики оценки моделей

Классификация

Да/Нет (Токсичность, ГЭБ, Pgr)


- ✓ **ROC-AUC**
Стандарт для сбалансированных данных.
- ✓ **PR-AUC**
Для несбалансированных данных (когда токсичных молекул мало).

Регрессия

Числа (Растворимость, Клиренс)

- ✓ **MAE**
Средняя абсолютная ошибка. Устойчива к выбросам.
- ✓ **Spearman ρ**
Ранговая корреляция. Оценивает правильность ранжирования (порядок).

Результаты эксперимента



Сравнение с лидерами

Модель	Задача	Категория	Метрика	Лучшая публичная модель	Лучший публичный результат	Результат GINE
GINE	Solubility_AqSolDB	Всасывание	mae	MiniMol	0.741	0.951
GINE	Bioavailability_Ma	Всасывание	roc_auc	MiniMol	0.942	0.676
GINE	Caco2_Wang	Всасывание	mae	CaliciBoost	0.256	0.319
GINE	HIA_Hou	Всасывание	roc_auc	MiniMol	0.993	0.971
GINE	Lipophilicity_AstraZeneca	Всасывание	mae	MiniMol	0.456	0.508
GINE	Pgp_Broccatelli	Всасывание	roc_auc	MapLight + GNN	0.938	0.924
GINE	CYP2C9_Veith	Метаболизм	auprc	MapLight + GNN	0.859	0.784
GINE	CYP2C9_Substrate_CarbonMangels	Метаболизм	auprc	MiniMol	0.474	0.372
GINE	CYP2D6_Veith	Метаболизм	auprc	MapLight + GNN	0.790	0.624
GINE	CYP2D6_Substrate_CarbonMangels	Метаболизм	auprc	ContextPred	0.736	0.825
GINE	CYP3A4_Veith	Метаболизм	auprc	MapLight + GNN	0.916	0.846
GINE	CYP3A4_Substrate_CarbonMangels	Метаболизм	roc_auc	CFA	0.667	0.666
GINE	Clearance_Hepatocyte_AZ	Метаболизм	spearman	CFA	0.536	0.574
GINE	Clearance_Microsome_AZ	Метаболизм	spearman	MapLight + GNN	0.630	0.515
GINE	Half_Life_Obach	Метаболизм	spearman	CFA	0.576	0.479
GINE	BBB_Martins	Распределение	roc_auc	MiniMol	0.924	0.921
GINE	PPBR_AZ	Распределение	mae	Gradient Boost	7.440	9.132
GINE	VDss_Lombardo	Распределение	spearman	MapLight + GNN	0.713	0.677
GINE	AMES	Токсичность	roc_auc	ZairaChem	0.871	0.840
GINE	DILI	Токсичность	roc_auc	MiniMol	0.956	0.863
GINE	LD50_Zhu	Токсичность	mae	BaseBoosting KyQVZ6b2	0.552	0.512
GINE	hERG	Токсичность	roc_auc	MapLight + GNN	0.880	0.875

Результаты:

- Подготовлены и обработаны наборы данных ADMET Benchmark из Therapeutics Data Commons.
- Реализованы молекулярные представления.
- Разработаны и реализованы пять нейросетевых архитектур.
- Проведено предобучение моделей GINE, Mamba и Transformer на вспомогательных задачах.
- Выполнено дообучение моделей на отдельных ADMET-задачах.
- Проведена оценка качества моделей.

Выводы:

- Разработаны и исследованы нейросетевые модели для прогнозирования ADMET-свойств лекарственно-подобных молекул. Наиболее универсальным среди рассмотренных подходов оказалось графовое представление молекулы, позволяющее учитывать как признаки атомов, так и признаки химических связей. Полученные результаты могут быть использованы при предварительном отборе лекарственных кандидатов и выборе архитектуры модели для конкретных задач хемоинформатики.

1. Huang K., Fu T., Gao W. et al. Therapeutics Data Commons: Machine Learning Datasets and Tasks for Drug Discovery and Development // Proceedings of Neural Information Processing Systems. 2021.
2. Rogers D., Hahn M. ExtendedConnectivity Fingerprints // Journal of Chemical Information and Modeling. 2010. Vol. 50, No. 5. P. 742–754.
3. Kipf T. N., Welling M. SemiSupervised Classification with Graph Convolutional Networks // International Conference on Learning Representations. 2017.
4. VaswaniA.,ShazeerN.,ParmarN.etal.AttentionIsAllYouNeed//Advances in Neural Information Processing Systems. 2017.
5. Devlin J., Chang M.W., Lee K., Toutanova K. BERT: Pretraining of Deep Bidirectional Transformers for Language Understanding // NAACLHLT. 2019.
6. GuA., Dao T. Mamba: LinearTime Sequence Modeling with Selective State Spaces. 2023.



Кафедра биомедицинской информатики

СПАСИБО ЗА ВНИМАНИЕ