

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
КАФЕДРА БИОМЕДИЦИНСКОЙ ИНФОРМАТИКИ

Отчёт

о прохождении преддипломной практики

Благодарного Артёма Андреевича
ФПМИ, БМИ, 4 курс 3 группа

Научный руководитель:
профессор, доктор
физико-математических наук,
Тузииков А.В.



Задачи на практику:

1. Изучение современных архитектур нейронных сетей, применяемых для анализа и предсказания свойств малых молекул.
2. Сравнение и теоретическое обоснование выбора архитектуры Matmba по сравнению с другими существующими архитектурами глубокого обучения.
3. Формирование, очистка и подготовка обучающего и тестового множеств данных для последующего обучения и оценки результатов предсказания.
4. Разработка и реализация программного прототипа нейросетевой архитектуры

Жизненный цикл лекарства: ADMEТ




- ▶ **Absorption** — попадание в кровоток
- ▶ **Distribution** — распределение по тканям
- ▶ **Metabolism** — биотрансформация
- ▶ **Excretion** — выведение из организма
- ▶ **Toxicity** — токсическое воздействие



SMILES: Линейная нотация структур

Acetylsalicylic acid







SMILES String:

```
CC(=O)Oc1ccccc1C(=O)O
```

- `c1ccccc1`: Ароматическое кольцо
- `(=O)`: Двойная связь с кислородом
- `()`: Ветвления функциональных групп

Архитектура: Mamba



Архитектура: Mamba

```
Mamba3CPUBlock(  
    (in_proj): Linear(in_features=128, out_features=512, bias=True)  
    (conv1d): Conv1d(256, 256, kernel_size=(4,), stride=(1,), padding=(3,), groups=256)  
    (x_proj): Linear(in_features=256, out_features=130, bias=True)  
    (out_proj): Linear(in_features=256, out_features=128, bias=True)  
)  
  
Mamba3Backbone(  
    (embedding): Embedding(128, 128, padding_idx=0)  
    (layers): ModuleList(  
      (0-3): 4 x Mamba3CPUBlock(  
        (in_proj): Linear(in_features=128, out_features=512, bias=True)  
        (conv1d): Conv1d(256, 256, kernel_size=(4,), stride=(1,), padding=(3,), groups=256)  
        (x_proj): Linear(in_features=256, out_features=130, bias=True)  
        (out_proj): Linear(in_features=256, out_features=128, bias=True)  
      )  
    )  
    (norm): LayerNorm((128,), eps=1e-05, elementwise_affine=True)  
)
```



Метрики оценки моделей



Классификация

Да/Нет (Токсичность, ГЭБ, Pgp)



ROC-AUC

Стандарт для сбалансированных данных.



PR-AUC

Для несбалансированных данных (когда токсичных молекул мало).



Регрессия

Числа (Растворимость, Клиренс)



MAE

Средняя абсолютная ошибка. Устойчива к выбросам.






Spearman ρ

Ранговая корреляция. Оценивает правильность ранжирования (порядок).

Предобучение

Mamba Pre-training on SMILES · 93 K parameters

32 768 sequences · 10 epochs · batch 256 · cosine LR with warm-up



Полученные результаты

ADMET Benchmark Results

Comparison across 22 tasks · Best results are bolded · MAE (lower is better), others (higher is better)

Task	Metric	Morgan MLP	CNN	GCN	Neural FP	Mamba
CL-Hepa	SPEARMAN	0.3379	0.2576	0.0109	-0.0191	0.1837
hERG	ROC-AUC	0.8094	0.6631	0.6313	0.6188	0.7181
AMES	ROC-AUC	0.7851	0.8033	0.7309	0.6192	0.8084
DILI	ROC-AUC	0.7934	0.8420	0.7778	0.6406	0.9045
LD50	MAE	0.5505	0.5764	0.7691	0.7076	0.5247
Caco2	MAE	0.4620	0.4269	1.0673	1.0135	0.4665
HIA	ROC-AUC	0.7970	0.8333	0.7091	0.6530	0.9152
Pgyp	ROC-AUC	0.9174	0.8483	0.7385	0.8022	0.8843
Bioav	ROC-AUC	0.5508	0.5938	0.4661	0.3503	0.6458
Lipo	MAE	0.7520	0.7430	0.9755	0.9580	0.7310
AqSol	MAE	1.2132	0.9899	1.3430	1.2948	0.9048
BBB	ROC-AUC	0.8982	0.9120	0.6130	0.7419	0.9027
PPBR	MAE	11.6106	9.4922	15.0284	15.7470	10.5187
VD	MAE	2.2708	2.3488	2.6383	2.5696	2.3306
CYP2D6-S	PR-AUC	0.7717	0.6379	0.4499	0.3984	0.7911
CYP3A4-S	ROC-AUC	0.6653	0.5504	0.5490	0.5380	0.7555
CYP2C9-S	PR-AUC	0.4015	0.4046	0.3773	0.3514	0.4915
Half-Life	SPEARMAN	0.5588	0.2702	0.0932	-0.1154	0.3396
CL-Micro	SPEARMAN	0.4725	0.3913	0.0357	0.0107	0.3929
CYP2D6-I	PR-AUC	0.6881	0.6445	0.3261	0.2607	0.5554
CYP3A4-I	PR-AUC	0.8169	0.7943	0.5560	0.5794	0.8017
CYP2C9-I	PR-AUC	0.7061	0.7228	0.5802	0.5367	0.7273

Спасибо за внимание!