

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
Кафедра биомедицинской информатики

**Отчёт
о прохождении преддипломной практики**

Благодарного Артёма Андреевича
Студента 4 курса
специальности «информатика»

Руководитель практики:
профессор, доктор
физико-математических наук,
Тузиков Александр Васильевич.

Минск, 2026

Оглавление

Введение	3
Глава 1. Характеристика деятельности организации «ЯндексБел»	5
Глава 2. Теоретический анализ методов предсказания ADMET-свойств и выбор архитектуры нейронной сети	7
2.1. Проблема прогнозирования ADMET-свойств малых молекул	7
2.2. Обзор современных архитектур глубокого обучения в хемоинформатике	8
2.3. Архитектура класса State Space Models (SSM) и модель Mamba.....	8
2.4. Сравнение и обоснование выбора архитектуры Mamba для решаемой задачи.....	9
Глава 3. Практическая реализация: подготовка данных и разработка прототипа	11
3.1. Выбор инструментария и организация рабочего пространства в VS Code.....	11
3.2. Специфика данных: строки SMILES	11
3.3. Разработка модуля аугментации химических данных	11
3.4. Токенизация и формирование обучающей выборки данных	12
3.5. Архитектура прототипа и настройка цикла обучения	12
Глава 4. Анализ результатов работы и приобретенные компетенции.....	14
4.1. Анализ полученных результатов.....	14
4.2. Приобретенные профессиональные навыки	16
Заключение	18
Перечень использованных источников	19

Введение

Современный этап развития фармакологии и хемоинформатики неразрывно связан с необходимостью оптимизации процесса разработки новых лекарственных препаратов, который остается длительным, дорогостоящим и высокорискованным. Одной из ключевых причин неудач на поздних фазах клинических испытаний является несоответствие синтезированных молекул фармакокинетическим характеристикам и профилю безопасности, объединяемым термином ADMET (всасывание, распределение, метаболизм, выведение и токсичность). Традиционные лабораторные исследования требуют колоссальных финансовых и временных затрат. Решением данной проблемы выступает разработка и внедрение интеллектуальных систем *in silico*-прогнозирования, которые трансформируют процесс поиска лекарств, позволяя с высокой точностью отсеивать бесперспективные соединения на самых ранних этапах.

Актуальность темы дипломной работы, в рамках которой проводится данная преддипломная практика, обусловлена необходимостью создания высокоэффективных алгоритмов для анализа текстовых представлений химических структур (SMILES). Доминирующая в последние годы архитектура Transformer имеет фундаментальный недостаток — квадратичную вычислительную сложность от длины последовательности, что затрудняет работу со сложными молекулярными графами. Переход от классических моделей глубокого обучения к моделям пространства состояний (State Space Models, SSM), к которым относится архитектура Mamba, является закономерным шагом в развитии предметной области. Mamba обеспечивает линейную вычислительную сложность и способна более эффективно моделировать длинный контекст химических связей.

Преддипломная практика является важнейшим этапом подготовки выпускной квалификационной работы. На данном этапе основной упор делается не на создание финального программного продукта, а на фундаментальное исследование предметной области, анализ существующих математических моделей нейронных сетей и проектирование теоретического и информационного фундамента будущей системы. В рамках практики осуществляется переход от теоретического изучения концепций к научно обоснованному выбору архитектуры, подготовке данных и созданию базового рабочего прототипа.

Целью преддипломной практики является комплексное исследование современных архитектур нейронных сетей для предсказания ADMET свойств малых молекул и реализация программного прототипа на базе оптимальной модели.

Для достижения поставленной цели в ходе практики необходимо решить следующие задачи:

1. Изучение современных архитектур нейронных сетей, применяемых для анализа и предсказания свойств малых молекул.
2. Сравнение и теоретическое обоснование выбора архитектуры Mamba по сравнению с другими существующими архитектурами глубокого обучения.
3. Формирование, очистка и подготовка обучающего и тестового множеств данных для последующего обучения и оценки результатов предсказания.
4. Разработка и реализация программного прототипа нейросетевой архитектуры.

Глава 1. Характеристика деятельности организации «ЯндексБел»

«Яндекс» представляет собой крупнейшую транснациональную IT-корпорацию, уверенно занимающую лидирующие позиции на рынке высоких технологий стран СНГ и далеко за его пределами. Начав свой исторический путь в конце 1990-х годов как инновационная текстовая поисковая система, за десятилетия непрерывного развития «Яндекс» трансформировался в масштабную глобальную экосистему. Сегодня диверсифицированный бизнес компании охватывает широчайший спектр передовых направлений: от флагманских решений в сфере электронной коммерции (Яндекс Маркет) и логистики (Яндекс Go) до разработки беспилотных транспортных средств, мощнейших сервисов облачных вычислений (Yandex Cloud) и создания прорывных систем генеративного искусственного интеллекта (виртуальный ассистент Алиса, нейросети семейства YandexGPT).

Особое и стратегически важное место в архитектуре компании занимает минский офис — ООО «ЯндексБел». Это не просто региональное представительство, а один из ключевых центров исследований и разработки (R&D) корпорации. Главным конкурентным преимуществом минского офиса является феноменально высокий уровень концентрации технических талантов. В стенах «ЯндексБел» трудятся ведущие инженеры отрасли, исследователи данных и архитекторы высоконагруженных систем. Корпоративная культура компании основывается на принципах высокого уровня инженерного качества, поддержке инициативности сотрудников и готовности к внедрению инновационных решений. Благодаря команде высококвалифицированных специалистов современные научные достижения и передовые методы оперативно интегрируются в практические продукты, которыми ежедневно пользуются миллионы пользователей.

Моя производственная практика проходила в одном из самых наукоемких подразделений компании — отделе, отвечающем за предобучение больших языковых моделей. Этап предобучения является фундаментальным и наиболее ресурсозатратным шагом в создании современных LLM (Large Language Model). В процессе такого обучения модель поглощает и анализирует терабайты неразмеченных текстовых данных, решая сложнейшую вычислительную задачу предсказания следующего токена.

Задачи, стоящие перед высококвалифицированными специалистами этого отдела, выходят далеко за рамки рутинного запуска скриптов на вычислительных кластерах. Деятельность команды включает в себя:

- Глубокую математическую и алгоритмическую оптимизацию архитектур нейронных сетей для радикального ускорения сходимости моделей;
- Масштабные исследования новейших парадигм машинного обучения, таких как Mixture of Experts (MoE) и State Space Models (SSM);
- Проектирование сверхнадежных конвейеров для обработки датасетов колоссальных размеров: их многоуровневую фильтрацию, дедупликацию и токенизацию;
- Решение нетривиальных проблем распределенного обучения и обеспечение максимальной утилизации гигантских вычислительных мощностей дата-центров.

В масштабах инфраструктуры Яндекса вопрос вычислительной эффективности инференса и обучения стоит крайне остро. Доминирующие сегодня классические архитектуры Transformer опираются на механизм Self-Attention. Его фундаментальный недостаток — квадратичная вычислительная сложность. На практике это означает, что при двукратном увеличении длины обрабатываемого контекста требования к вычислительным ресурсам и оперативной памяти возрастают в четыре раза. В связи с этим передовая индустрия и исследовательские центры Яндекса активно ищут пути преодоления этого барьера, обращая пристальное внимание на архитектуры на базе SSM (в частности, Mamba). Они демонстрируют качество предсказаний, сопоставимое с трансформерами, но обладают линейной сложностью, что открывает новые горизонты в оптимизации ресурсов.

Глава 2. Теоретический анализ методов предсказания ADMET-свойств и выбор архитектуры нейронной сети

В данной главе решаются первые две задачи исследования: проводится всестороннее изучение современных архитектур глубокого обучения, применяемых в хемоинформатике, и приводится теоретическое обоснование выбора архитектуры Mamba для решения поставленной задачи [8].

2.1. Проблема прогнозирования ADMET-свойств малых молекул

Разработка новых лекарственных препаратов — это крайне длительный и дорогостоящий процесс. Одной из главных причин провала потенциальных лекарственных кандидатов на поздних стадиях клинических испытаний являются неудовлетворительные фармакокинетические свойства и высокая токсичность. В фармакологии эти свойства объединяются аббревиатурой ADMET, которая расшифровывается как:

- Absorption (Всасывание) — способность вещества проникать в кровоток;
- Distribution (Распределение) — распространение вещества по тканям организма;
- Metabolism (Метаболизм) — расщепление вещества ферментами;
- Excretion (Выведение) — процесс выведения метаболитов из организма;
- Toxicity (Токсичность) — негативное воздействие на организм (гепатотоксичность, кардиотоксичность, мутагенность и др.).

Прогнозирование *in silico* (с использованием компьютерного моделирования) позволяет отсеивать заведомо неудачные молекулы еще до начала этапа синтеза и лабораторных испытаний, что радикально экономит время и ресурсы фармацевтических компаний [3].

Для применения алгоритмов машинного обучения химическую структуру молекул необходимо преобразовать в машиночитаемый формат. Исторически сложилось два основных подхода к представлению молекул:

- Молекулярные графы: Молекула представляется в виде графа, где вершины — это атомы (с признаками типа атома, заряда, гибридизации), а ребра — химические связи.
- Строковые нотации (например, SMILES): Simplified Molecular Input Line Entry System (SMILES) — это способ записи структуры молекулы в виде линейной последовательности символов. Этот формат позволяет применять к химическим данным мощные методы обработки естественного языка (NLP), рассматривая молекулу как «предложение», а атомы и связи — как «слова» [1].

2.2. Обзор современных архитектур глубокого обучения в хемоинформатике

С развитием искусственного интеллекта подходы к анализу химических данных значительно эволюционировали. В настоящее время в хемоинформатике доминируют три основных класса архитектур глубокого обучения:

Рекуррентные нейронные сети. Изначально именно они стали стандартом для работы с последовательностями SMILES. Архитектуры LSTM (Long Short-Term Memory) способны запоминать информацию о предыдущих символах в строке. Однако они имеют существенные недостатки: последовательная обработка данных делает невозможным эффективное распараллеливание вычислений на GPU, а на длинных молекулах сети все равно страдают от проблемы затухания градиента [4].

Графовые нейронные сети. Они работают напрямую с молекулярными графами, что является наиболее естественным представлением химической структуры. Они отлично улавливают локальные структурные особенности (например, наличие бензольных колец). Тем не менее, классические графовые нейронные сети сталкиваются с проблемой «пересглаживания» при увеличении числа слоев и плохо справляются с захватом глобального контекста молекулы (взаимодействием атомов, находящихся далеко друг от друга) [5].

Трансформеры. Архитектура Transformer, произведшая революцию в NLP, стала новым стандартом и в химии. Благодаря механизму внутреннего внимания Трансформеры способны находить зависимости между любыми символами в строке SMILES, независимо от расстояния между ними. Главный минус Трансформеров — их вычислительная сложность. Механизм Self-Attention требует сравнения каждого токена с каждым, что приводит к квадратичной вычислительной сложности по времени и по памяти [6].

При работе с большими базами данных или длинными молекулярными структурами обучение и инференс таких моделей становятся крайне ресурсоемкими.

2.3. Архитектура класса State Space Models (SSM) и модель Mamba

В ответ на ограничения Трансформеров исследователями был предложен новый класс архитектур — State Space Models (SSM), базирующийся на математических моделях пространства состояний из теории управления. Классические SSM позволяют моделировать непрерывные сигналы и эффективно дискретизировать их для работы с последовательностями [7].

РевOLUTIONНЫМ прорывом в этом направлении стала архитектура Mamba. В отличие от предыдущих SSM, параметры которых были фиксированы для всей последовательности, Mamba вводит механизм селективного сканирования.

Суть механизма заключается в том, что модель учится зависеть от входных данных: она может динамически решать, какую информацию из последовательности стоит «запомнить» в скрытом состоянии, а какую — проигнорировать. Этот подход позволяет Mamba:

1. Фильтровать шум и выделять только важные химические паттерны.
2. Поддерживать глобальный контекст на неограниченно длинных последовательностях.

Главное преимущество Mamba перед Трансформерами — это использование оптимизированного на аппаратном уровне алгоритма параллельного сканирования. Благодаря этому Mamba достигает линейной вычислительной сложности. Она работает с длинными последовательностями в несколько раз быстрее Трансформеров и потребляет значительно меньше памяти при сопоставимом или даже более высоком качестве предсказаний.

2.4. Сравнение и обоснование выбора архитектуры Mamba для решаемой задачи

Для окончательного обоснования выбора архитектуры для предсказания ADMET-свойств сведем характеристики рассмотренных подходов в сравнительную таблицу.

Характеристика	Graph Neural Networks (GNN)	Transformers (ChemBERTa)	Mamba (SSM)
Формат входных данных	Графы	SMILES (строки)	SMILES (строки)
Вычислительная сложность	$O(V+E)$ (Квадратичная)	$O(N^2)$ (Квадратичная)	$O(N)$ (Линейная)
Потребление памяти	$O(V+E)$	$O(N^2)$ (Квадратичная)	$O(N)$ (Линейная)

Рис. 1. Сравнительный анализ архитектур нейронных сетей для задач хемоинформатики

Анализ показывает, что Трансформеры обеспечивают высокое качество работы с

контекстом SMILES-последовательностей, но их использование ограничено квадратичной ресурсоемкостью. Графовые сети быстры, но уступают в захвате глобальных зависимостей сложной молекулы.

Архитектура Mamba представляет собой оптимальный компромисс, лишенный этих недостатков. Она объединяет в себе способность Трансформеров понимать сложный, длинный контекст химической нотации (благодаря селективному сканированию) со скоростью и низким потреблением памяти классических рекуррентных сетей (благодаря линейной сложности).

Таким образом, для решения задачи *in silico* прогнозирования ADMET-параметров выбор архитектуры Mamba является наиболее обоснованным, современным и перспективным решением.

Глава 3. Практическая реализация: подготовка данных и разработка прототипа

3.1. Выбор инструментария и организация рабочего пространства в VS Code

Для реализации проекта был выбран классический инструмент разработки. Вся кодовая база писалась и отлаживалась в Visual Studio Code. Выбор VS Code был обусловлен несколькими факторами:

- Отличная интеграция с виртуальными окружениями.
- Наличие удобного инструмента отладки кода.

Используемый стек технологий: язык программирования python, PyTorch — основной фреймворк глубокого обучения, RDKit — промышленный стандарт в области хемоинформатики для парсинга и валидации молекул, NumPy, Pandas, tqdm — для манипуляций с данными и логирования.

3.2. Специфика данных: строки SMILES

В качестве языка данных использовался SMILES. SMILES кодирует топологию молекулярного графа в виде строки. Для языковой модели эти символы — просто токены. Задачей этапа претрейна является обучение модели вероятностному распределению символов. Модель должна понять, что после символа C (Углерод) с высокой долей вероятности может идти C, O (Кислород) или N (Азот), но не может идти закрывающая скобка, если до этого не было открывающей. Таким образом, языковая модель через задачу предсказания следующего токена выучивает физико-химические законы валентности и топологии колец.

3.3. Разработка модуля аугментации химических данных

При обучении на небольших датасетах (в данном случае около 32 тысяч молекул) языковые модели склонны к переобучению. В NLP для аугментации используют замену синонимов, но в химии есть более элегантный метод.

Этот метод называется рандомизацией SMILES. Поскольку молекула представляет собой неориентированный граф, алгоритм обхода этого графа для генерации строки SMILES может начинаться с любого атома. Следовательно, одна и та же молекула может быть записана десятками различных, но химически абсолютно валидных строк SMILES.

Для реализации этого подхода был написан специальный модуль с использованием библиотеки RDKit. В процессе загрузки данных молекула сначала конвертировалась из канонического SMILES в объект графа RDKit, а затем конвертировалась обратно в строку с флагом случайной генерации пути. Данная техника позволила искусственно увеличить размер обучающей выборки в

несколько раз, заставляя архитектуру Mamba фокусироваться на инвариантной химической структуре, а не заучивать конкретные последовательности символов.

3.4. Токенизация и формирование обучающей выборки данных

Для передачи строковых данных в нейронную сеть был разработан токенизатор. Был выбран подход токенизации на уровне символов с выделением специфических химических паттернов. Процесс подготовки данных включал следующие шаги:

1. Создание словаря: сбор всех уникальных символов из тренировочного датасета и присвоение им целочисленных индексов.
2. Добавление спецтокенов: в словарь были интегрированы токены <PAD> (для выравнивания длин строк), <BOS> (начало последовательности) и <EOS> (конец последовательности).
3. Имплементация PyTorch Dataset: Написание класса, наследуемого от, который на лету проводит аугментацию токенизирует строку и преобразует ее в тензор PyTorch.

Для удобной подачи данных во время обучения был реализован класс DataLoader для упаковки данных в батчи и эффективного использования матричных вычислений центрального процессора.

3.5. Архитектура прототипа и настройка цикла обучения

В рамках прототипирования на CPU была инициализирована базовая архитектура State Space Model (Mamba).

Модель состоит из слоя эмбеддингов, нескольких блоков Mamba и финального линейного слоя, проецирующего скрытые состояния обратно в размерность словаря токенов.

В качестве функции потерь использовалась перекрестная энтропия, стандартная для задач авторегрессионного моделирования языка. Оптимизация весов производилась с помощью алгоритма AdamW.

Разработка полноценного цикла обучения с логированием потерь в консоль на CPU позволила полностью отладить логику передачи скрытых состояний, корректность маскирования padding-токенов и работу аугментации для тонкой настройки под конкретные ADMET-задачи.

3.6. Предобучение Mamba

Для отладки архитектуры и проверки корректности пайплайна подготовки данных был инициализирован прототип модели Mamba с малым числом параметров — 93 000. Использование такой легковесной модели позволило провести полный цикл обучения на центральном процессоре в приемлемые сроки.

Обучение проводилось на выборке, состоящей из 32 768 уникальных SMILES-последовательностей. Процесс длился 10 эпох. Для обеспечения эффективности матричных вычислений данные подавались пакетами по 256 последовательностей в каждом.




Рис. 2. Графики лосса, перплексии и LR во время предобучения

Была применена стратегия косинусного затухания с предварительным разогревом (график С). Качество предсказания следующего символа оценивалось с помощью функции потерь перекрестной энтропии. Результаты представлены на графике (А). Как видно из графика, обучение демонстрирует устойчивую и быструю сходимость. Отсутствие резких скачков на кривой обучения подтверждает правильность выбора гиперпараметров и корректную работу механизма селективного сканирования Mamba при работе с химическими данными.

В задачах обработки естественного языка и хемоинформатики стандартной метрикой качества генеративных моделей является перплексия (Perplexity), которая математически представляет собой экспоненту от значения кросс-энтропии. Динамика этой метрики отражена на графике (В).

Перплексия физически интерпретируется как «степень растерянности» модели — из скольких равновероятных вариантов токенов модель делает выбор на каждом шаге.

Глава 4. Анализ результатов работы и приобретенные компетенции

4.1. Анализ полученных результатов

На завершающем этапе исследования предобученная модель Mamba была подвергнута процедуре тонкой настройки для решения конкретных задач прогнозирования фармакокинетических свойств и токсичности.

Для объективной оценки качества предложенной архитектуры было проведено масштабное тестирование на стандартизированном бенчмарке ADMET, включающем 22 различные задачи.

В качестве метрик оценки использовались:

- Для задач бинарной классификации: площадь под кривой ошибок ROC-AUC и кривой точности-полноты PR-AUC. Чем выше значение, тем лучше.
- Для задач регрессии: средняя абсолютная ошибка (MAE). Чем ниже значение, тем лучше.
- Для оценки ранговой корреляции: коэффициент Спирмена. Чем выше значение, тем лучше.

Производительность архитектуры Mamba сравнивалась с четырьмя базовыми моделями:

- Morgan MLP — многослойный перцептрон, обучаемый на классических молекулярных отпечатках
- CNN — сверточная нейронная сеть
- GCN — графовая сверточная нейронная сеть (Graph Convolutional Network)
- Neural FP — нейронные молекулярные отпечатки

Анализ эмпирических данных, представленных в сводной таблице результатов, позволяет сделать вывод о высокой конкурентоспособности предложенного подхода. Модель Mamba продемонстрировала наилучшие результаты 11 из 22 задач, что составляет ровно 50% от всего бенчмарка.

Вторым по эффективности оказался классический подход Morgan MLP, показавший лучший результат в 8 задачах. Архитектура CNN оказалась оптимальной для 3 задач. Примечательно, что графовые нейронные сети не смогли превзойти конкурентов ни в одной из метрик. Этот факт подтверждает теоретическое обоснование из Главы 2: на относительно небольших ADMET-датасетах графовые сети часто страдают от проблемы пересглаживания и не способны эффективно извлекать глобальный контекст молекулы по сравнению с моделями, работающими с последовательностями (SMILES).

ADMET Benchmark Results

Comparison across 22 tasks · Best results are bolded · MAE (lower is better), others (higher is better)

Task	Metric	Morgan MLP	CNN	GCN	Neural FP	Mamba
CL-Hepa	SPEARMAN	0.3379	0.2576	0.0109	-0.0191	0.1837
hERG	ROC-AUC	0.8094	0.6631	0.6313	0.6188	0.7181
AMES	ROC-AUC	0.7851	0.8033	0.7309	0.6192	0.8084
DILI	ROC-AUC	0.7934	0.8420	0.7778	0.6406	0.9045
LD50	MAE	0.5505	0.5764	0.7691	0.7076	0.5247
Caco2	MAE	0.4620	0.4269	1.0673	1.0135	0.4665
HIA	ROC-AUC	0.7970	0.8333	0.7091	0.6530	0.9152
Pgp	ROC-AUC	0.9174	0.8483	0.7385	0.8022	0.8843
Bioav	ROC-AUC	0.5508	0.5938	0.4661	0.3503	0.6458
Lipo	MAE	0.7520	0.7430	0.9755	0.9580	0.7310
AqSol	MAE	1.2132	0.9899	1.3430	1.2948	0.9048
BBB	ROC-AUC	0.8982	0.9120	0.6130	0.7419	0.9027
PPBR	MAE	11.6106	9.4922	15.0284	15.7470	10.5187
VD	MAE	2.2708	2.3488	2.6383	2.5696	2.3306
CYP2D6-S	PR-AUC	0.7717	0.6379	0.4499	0.3984	0.7911
CYP3A4-S	ROC-AUC	0.6653	0.5504	0.5490	0.5380	0.7555
CYP2C9-S	PR-AUC	0.4015	0.4046	0.3773	0.3514	0.4915
Half-Life	SPEARMAN	0.5588	0.2702	0.0932	-0.1154	0.3396
CL-Micro	SPEARMAN	0.4725	0.3913	0.0357	0.0107	0.3929
CYP2D6-I	PR-AUC	0.6881	0.6445	0.3261	0.2607	0.5554
CYP3A4-I	PR-AUC	0.8169	0.7943	0.5560	0.5794	0.8017
CYP2C9-I	PR-AUC	0.7061	0.7228	0.5802	0.5367	0.7273

Рис. 3. Таблица значений бенчмарков для выбранных моделей

Для более глубокого понимания специфики работы модели Mamba, результаты целесообразно разделить по фармакологическим категориям:

1. **Токсичность.** Модель Mamba продемонстрировала абсолютное превосходство в задачах оценки безопасности молекул. Она показала высшие баллы в предсказании мутагенности, гепатотоксичности и острой токсичности. Это свидетельствует о способности селективного сканирования выявлять скрытые, неочевидные токсикофорные паттерны в структуре SMILES.

2. **Абсорбция и Физико-химические свойства.** В этой категории Mamba также показала высокую надежность, выиграв в задачах предсказания абсорбции в кишечнике человека, биодоступности, липофильности и растворимости в воде.

Стоит отметить, что архитектура CNN оказалась эффективнее в локальных задачах проницаемости барьеров.

3. Метаболизм и Выведение. В данной группе наблюдается интересное разделение. Модель Mamba оказалась наиболее точной в определении того, является ли молекула субстратом для ферментов печени цитохрома P450. Однако классический алгоритм Morgan MLP показал лучшие результаты в задачах клиренса, периода полувыведения и ингибирования ферментов. Успех Morgan MLP здесь объясняется тем, что свойства выведения часто зависят от наличия строго определенных, жестких химических субструктур, которые алгоритмы Fingerprints улавливают «из коробки», тогда как языковым моделям сложнее выделить их на фоне глобального контекста [2].

Сравнительный анализ показал, что архитектура Mamba, основанная на моделях пространства состояний, является мощным и универсальным инструментом для *in silico* скрининга малых молекул. Модель успешно переносит химическую интуицию, полученную на этапе предобучения, на конкретные задачи, превосходя современные графовые нейронные сети и классические дескрипторные методы в половине тестов. Особенно сильной стороной предложенной архитектуры является прогнозирование токсичности и базовых физико-химических характеристик, что делает ее крайне перспективной для интеграции в реальные пайплайны разработки лекарственных препаратов.

4.2. Приобретенные профессиональные навыки

В ходе прохождения производственной практики в отделе LLM Pretrain компании Яндекс были получены следующие практические навыки:

Технические навыки:

- Глубокое понимание State Space Models: Проанализированы научные статьи, включая Mamba, и реализована адаптация архитектуры в коде. Освоены механизмы дискретизации матриц.
- PyTorch на продвинутом уровне: Приобретены навыки работы с тензорными операциями, отладки графов вычислений, кастомизации циклов обучения без использования высокоуровневых оберток
- Хемоинформатика и RDKit: Получен опыт работы с библиотекой RDKit, глубокое понимание формата SMILES, реализованы сложные алгоритмы аугментаций данных на основе молекулярных графов.

Гибкие навыки:

- Автономность в решении R&D задач: Продемонстрирована способность самостоятельно декомпозировать абстрактную задачу на конкретные шаги разработки.

- Аналитическое мышление: Развита способность интерпретации логов обучения и понимания причин, по которым модель не сходится.
- Адаптивность: Проявлена способность быстро погружаться в новую предметную область и находить точки пересечения технологий.

Заключение

Производственная практика в компании «ЯндексБел» стала важнейшим этапом закрепления академических знаний и перевода их в плоскость индустриальной разработки. В ходе практики была успешно решена научно-прикладная задача: реализован пайплайн предварительного обучения архитектуры State Space Model Mamba для химических текстов SMILES с условием выполнения на CPU.

Был разработан и интегрирован уникальный механизм аугментации молекулярных данных с помощью библиотеки RDKit, который генерирует неканонические SMILES, обеспечивая регуляризацию модели и предотвращая переобучение на ограниченном корпусе данных в 32 768 примеров.

Разработанный в среде VS Code код доказал свою работоспособность: модель продемонстрировала уверенное снижение функции потерь и перплексии. В ходе тестирования модель показала превосходство над существующими аналогами в 11 из 22 поставленных задач, что подтверждает её высокую эффективность и потенциал. Практически подтверждено, что в отличие от классических Трансформеров, Mamba обладает предсказуемым линейным потреблением памяти, что делает ее использование на центральных процессорах технически целесообразным и масштабируемым решением для задач хемоинформатики и ADMET-прогнозирования.

Опыт, полученный в отделе предобучения больших языковых моделей, позволил взглянуть на машинное обучение не просто как на запуск готовых библиотек, но как на глубокую инженерную дисциплину, где понимание низкоуровневых операций матричного умножения и управления памятью напрямую влияет на успешность исследовательского проекта. Впечатления от практики исключительно положительные: это колоссальный скачок в понимании того, как устроены современные модели "под капотом" и как IT-гиганты оптимизируют алгоритмы под реальную инфраструктуру.

Перечень использованных источников

1. Wang Y., Ouyang R., Zhan W., ..., Zhuang Z. SMILES-Mamba: A Mamba-based Molecular Foundation Model. arXiv preprint arXiv:2408.05696, 2024. Available at: <https://arxiv.org/abs/2408.05696> (accessed 10.12.2025).
2. Weininger D. SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 1988, vol. 28, no. 1, pp. 31–36. <https://doi.org/10.1021/ci00057a005>
3. Kotsias P. C., Arús-Pous J., Chen H., Papadopoulos K., ..., Tyrchan C. Direct steering of de novo molecular generation with descriptor conditional recurrent neural networks. *Nature Machine Intelligence*, 2020, vol. 2, no. 5, pp. 254–265. <https://doi.org/10.1038/s42256-020-0174-5>
4. Li Q., Han Z., Wu X. M. Deeper insights into graph convolutional networks for semi-supervised learning. *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, 2018. Available at: <https://ojs.aaai.org/index.php/AAAI/article/view/11604>
5. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., ..., Polosukhin I. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, no. 30. (See also: Chithrananda S., Grand G., Ramsundar B. ChemBERTa: Large-Scale Self-Supervised Pretraining for Molecular Property Prediction, 2020.) <https://arxiv.org/abs/1706.03762>
6. Gu A., Dao T. Mamba: Linear-time sequence modeling with selective state spaces. arXiv preprint arXiv:2312.00752, 2023. Available at: <https://arxiv.org/abs/2312.00752>
7. Huang K., Xiao C., Glass L. M., Zitnik M., ..., Sun J. Therapeutics Data Commons: Machine Learning Datasets and Tasks for Drug Discovery and Development. arXiv preprint arXiv:2102.09548, 2021. Available at: <https://arxiv.org/abs/2102.09548>
8. Wang Y., Ouyang R., Zhan W. SMILES-Mamba: A Mamba-based Molecular Foundation Model. arXiv preprint arXiv:2408.05696, 2024.